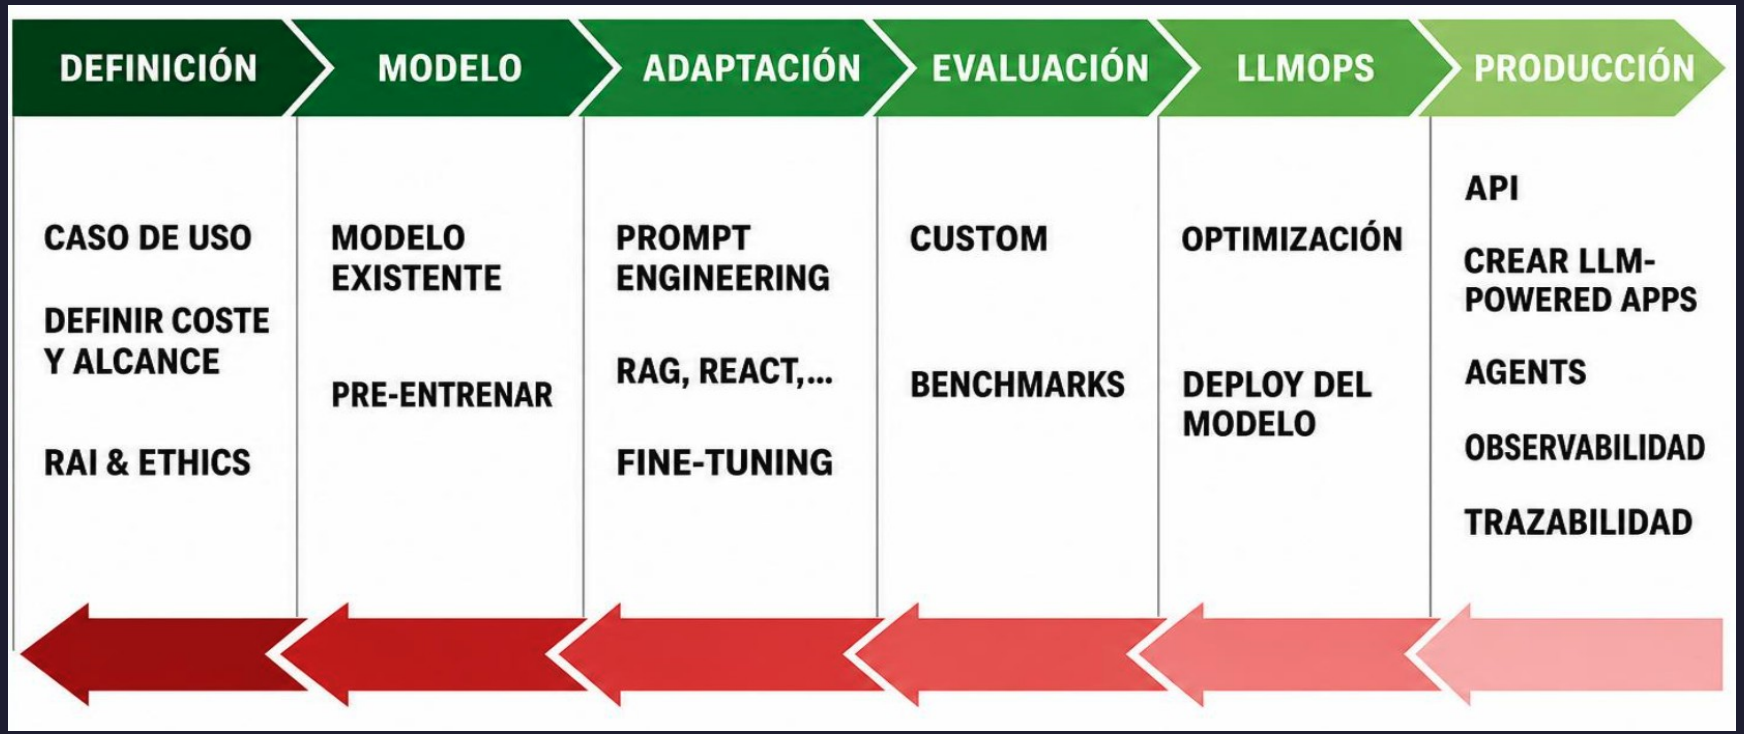
keep coding

AI ENGINEERING

Mixture of Experts


DEFINICIÓN
MODELO
ADAPTACIÓN
EVALUACIÓN
LLMOPS
PRODUCCIÓN
CASO DE USO
DEFINIR COSTE Y ALCANCE
RAI & ETHICS
MODELO EXISTENTE
PRE-ENTRENAR
PROMPT ENGINEERING
RAG, REACT,...
FINE-TUNING
CUSTOM
BENCHMARKS
OPTIMIZACIÓN
DEPLOY DEL MODELO
API
CREAR LLM-POWERED APPS
AGENTS
OBSERVABILIDAD
TRAZABILIDAD

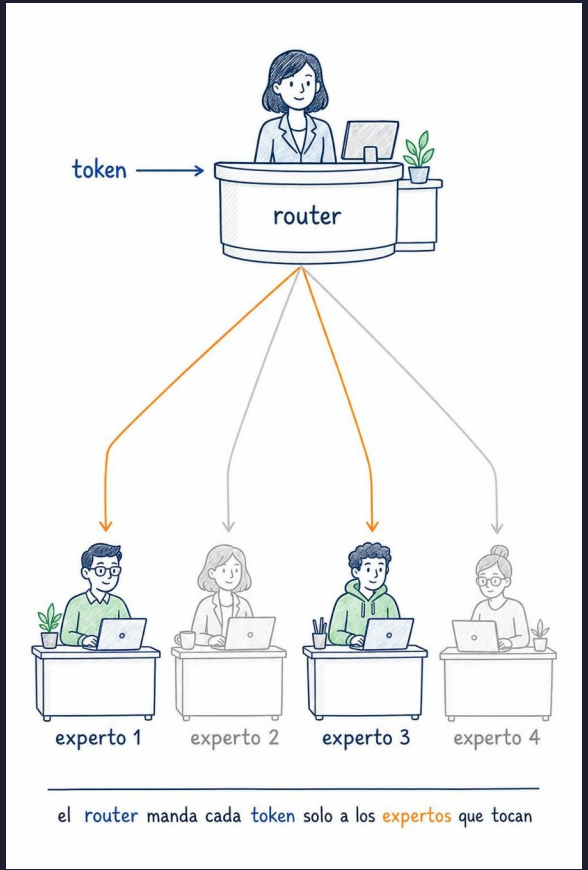
La idea, con una analogía

keep coding

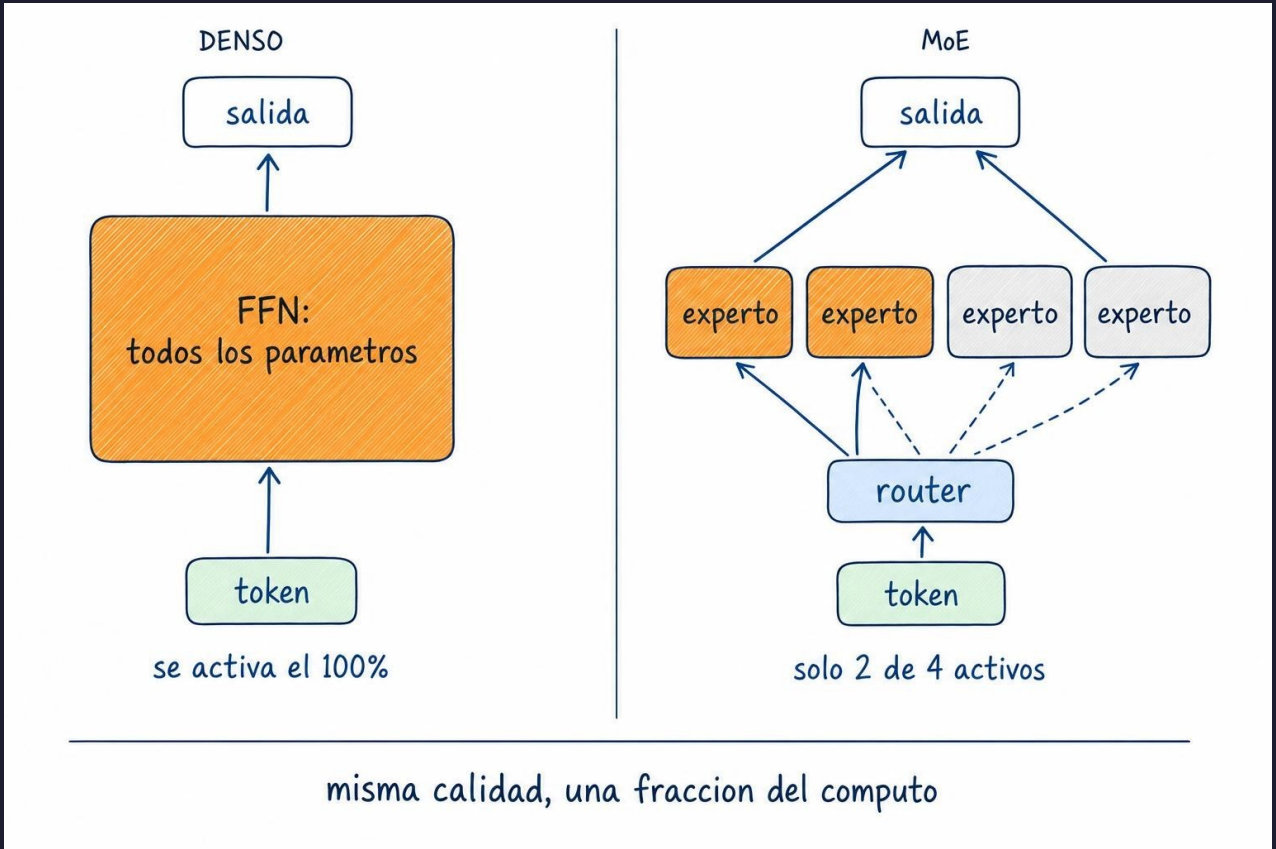
- Modelo **denso** = un cerebro que usa TODAS sus neuronas para cada token. Potente, pero caro.

- **MoE** = especialistas + un **router (recepcionista)** que manda cada token solo a los que tocan.

- Tienes el conocimiento de **todo el equipo**, pero por token solo trabajan unos pocos.



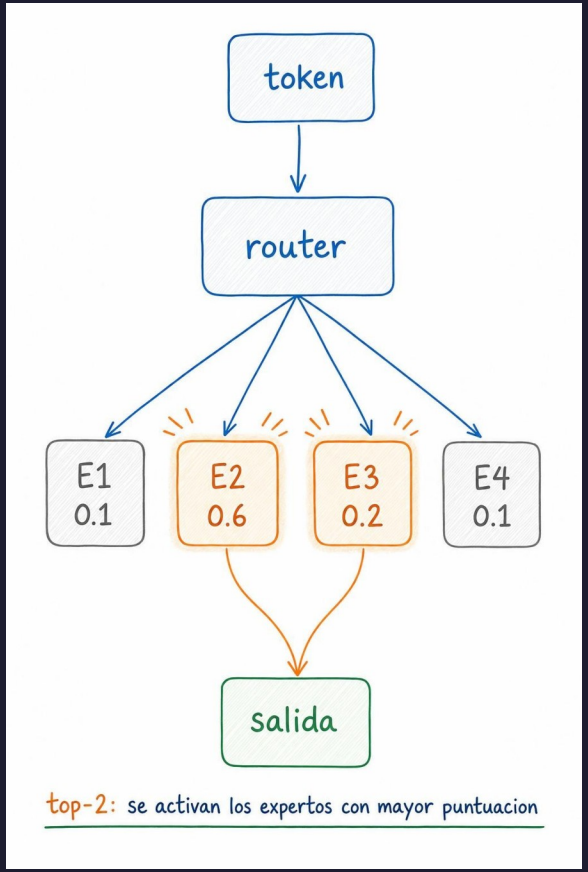
Denso vs MoE


DENSO
salida
FFN:
todos los parametros
token
se activa el 100%
MoE
salida
experto
experto
experto
experto
router
token
solo 2 de 4 activos
misma calidad, una fraccion del computo

¿Qué es MoE?

keep coding

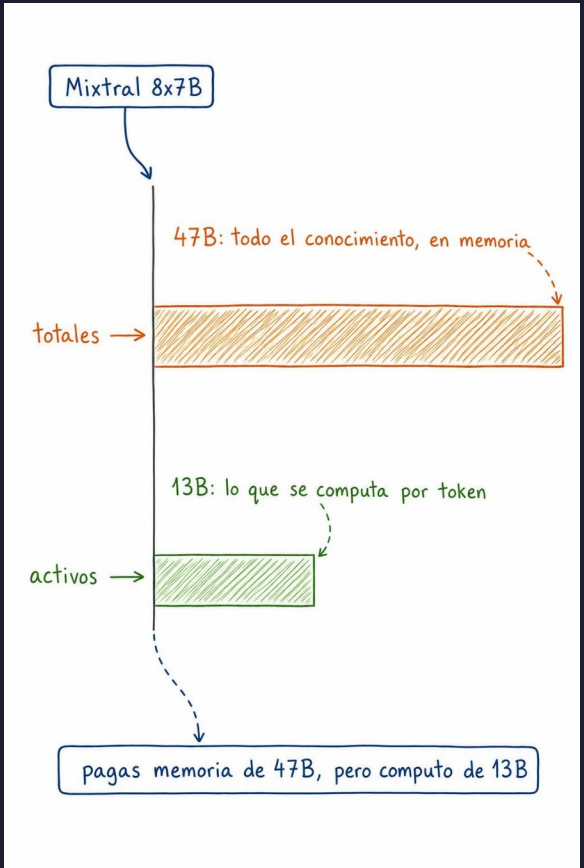
- Cada capa cambia el **FFN denso por N expertos** (cada experto es un FFN).
- Un **router** puntúa los expertos y elige los **top-k** para cada token.
- Mixtral: top-2 de 8. DeepSeek-V3: top-8 de 256. La **especialización surge sola** al entrenar.



El truco: totales vs activos

keep coding

- **Totales** = todo el conocimiento del modelo (todos los expertos, en memoria).
- **Activos** = lo que se computa por token (solo los k expertos elegidos).
- **El conocimiento escala**; el cómputo, casi no.



¿Por qué importa?

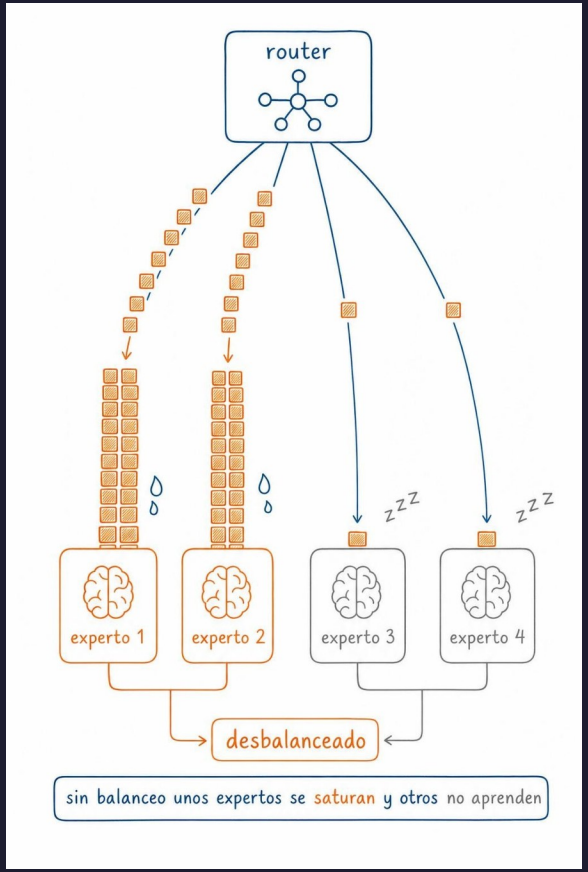
keep coding

- Escalas **capacidad añadiendo expertos**, sin disparar el coste de inferencia.
- Con el **mismo presupuesto de cómputo**, obtienes un modelo mucho más capaz.
- Por eso casi todo el **frontier abierto de 2026 es MoE**: DeepSeek, Llama 4, Qwen3.5, GPT-OSS.

Desafíos

keep coding

- **Load balancing**: el router satura unos expertos y deja otros «vagos». Se corrige con loss auxiliar (Switch) o bias dinámico (DeepSeek-V3).
- **Memoria**: todos los expertos viven en VRAM aunque solo uses k. MoE ahorra cómputo, no memoria.
- **Servir MoE es más complejo**: routing y sharding de expertos entre GPUs.



Ejemplos en 2026

keep coding

Modelo	Totales	Activos	Expertos · top-k
Mixtral 8x7B	47B	13B	8 · top-2
DeepSeek-V3	671B	37B	256 · top-8
Llama 4 Maverick	400B	17B	128 · top-1
Qwen3.5	397B	17B	MoE

El ratio activos/total cae año a año: 25% (Mixtral) → ~4% (Llama 4, Qwen3.5) → ~3% (DeepSeek-V4, 1.6T/49B).

Recap

keep coding

- MoE = **N expertos + un router** que activa solo k por token.
- **Ganas**: la capacidad de un modelo enorme al coste de cómputo de uno pequeño.
- **Cuesta**: memoria (todos los expertos en VRAM) y complejidad de entrenamiento y servido.
- **Resultado**: la arquitectura por defecto del frontier abierto en 2026.



www.keepcoding.io cursos@keepcoding.io (+34) 916 33 1779