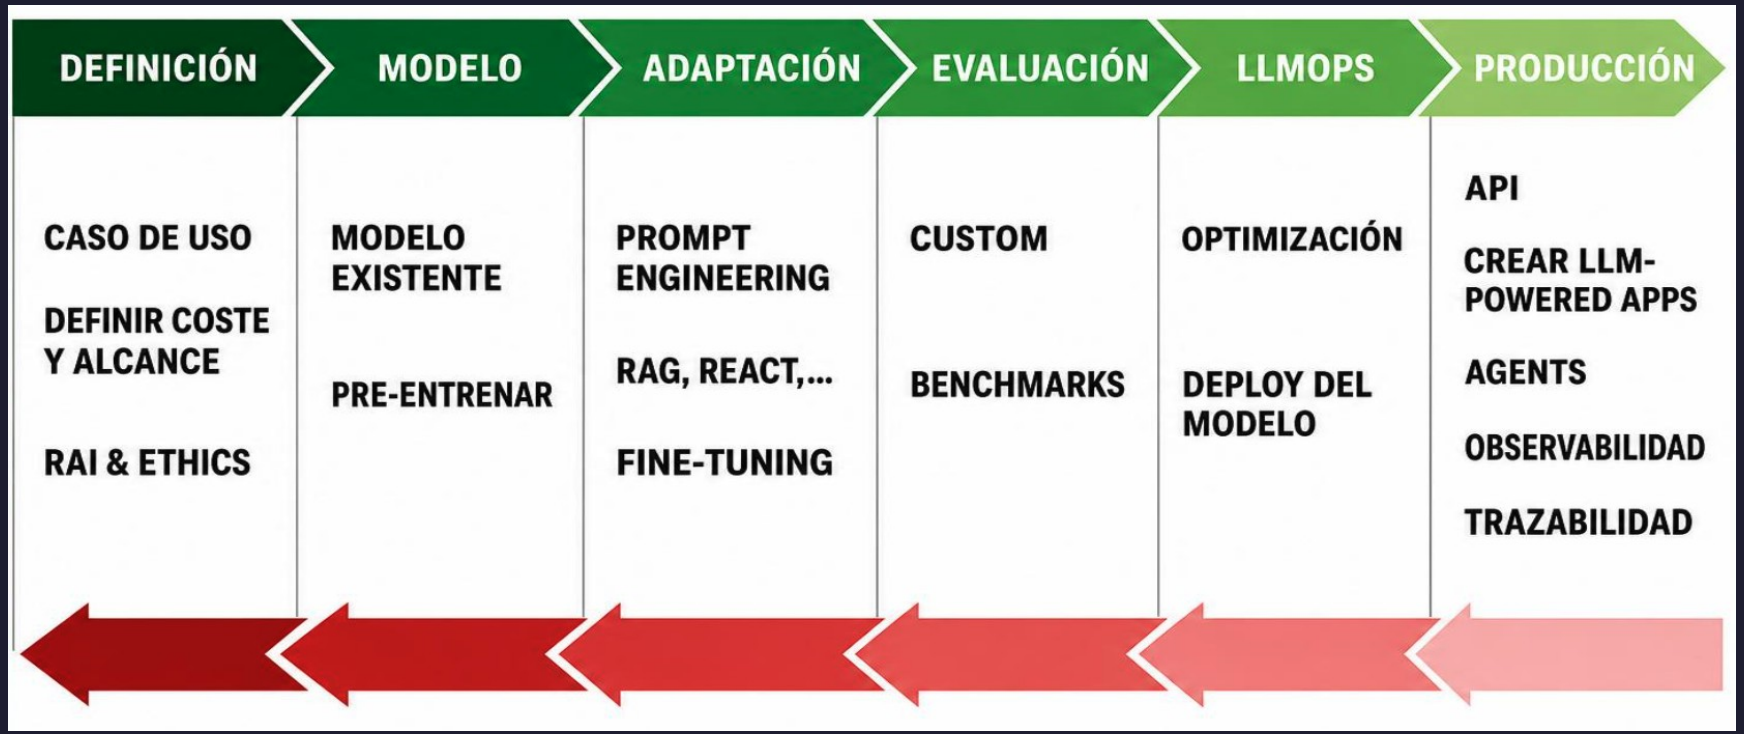
keep coding

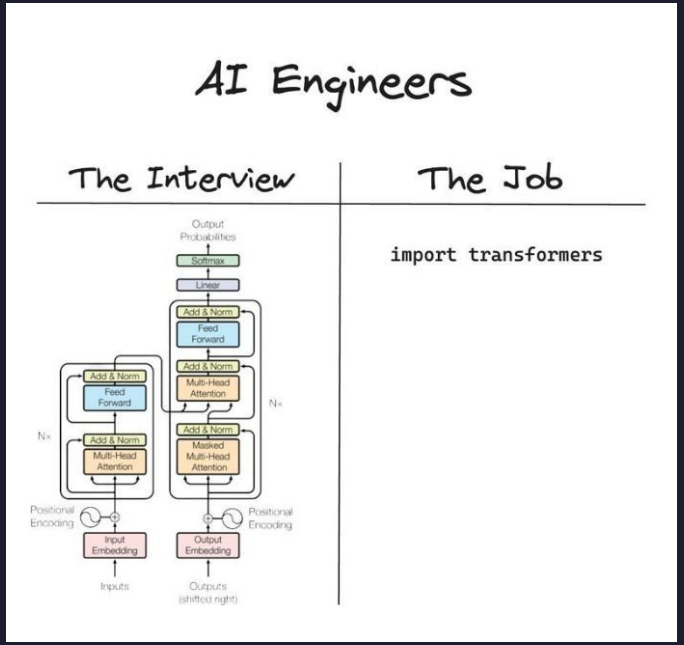
AI ENGINEERING

LLMOps + Local LLMs


DEFINICIÓN
MODELO
ADAPTACIÓN
EVALUACIÓN
LLMOPS
PRODUCCIÓN
CASO DE USO
DEFINIR COSTE Y ALCANCE
RAI & ETHICS
MODELO EXISTENTE
PRE-ENTRENAR
PROMPT ENGINEERING
RAG, REACT,...
FINE-TUNING
CUSTOM
BENCHMARKS
OPTIMIZACIÓN
DEPLOY DEL MODELO
API
CREAR LLM-POWERED APPS
AGENTS
OBSERVABILIDAD
TRAZABILIDAD

HuggingFace

- Creación: año 2016
- Fundadores: Clément Delangue, Julien Chaumond, Thomas Wolf.
- Actividad principal: IA y NLP
- Conocidos por: la librería transformers y el Hub de modelos



Modelos

- Facilitar acceso a modelos de IA.
- Modelos de NLP, visión por computadora, audio.
- Comunidad OpenSource, empresas, investigadores.
- Investigación, desarrollo de productos, aplicaciones educativas.



Datasets

- Amplia biblioteca de datasets.
- Datasets de NLP, visión por computadora, audio.
- Abiertos por la comunidad, empresas, investigadores.
- Entrenamiento de modelos de IA, investigación, educación.





https://huggingface.co/datasets/machinelearnear/multiturn_chat_milei_gpt

Spaces

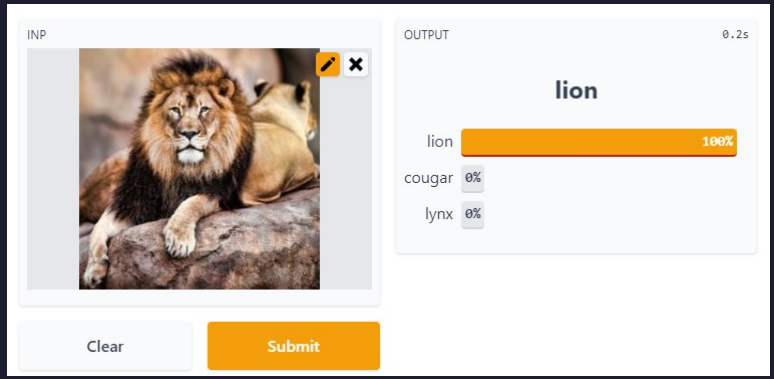
keep coding

- Plataforma para demostraciones y aplicaciones de IA.
- Ejecución de modelos de IA en tiempo real.
- Creados por desarrolladores, investigadores, aficionados a la IA.
- Prototipado rápido, demostraciones interactivas, educación en IA.



Gradio

- https://www.gradio.app/
- Interfaces de forma rápida y sencilla.
- Facilita a los usuarios probar modelos mediante la introducción de datos y la visualización de las predicciones en tiempo real.
- Diseñado para que tanto desarrolladores como no expertos puedan interactuar fácilmente con modelos de inteligencia artificial.



Optimizaciones para inferencia

- Proceso para mejorar la eficiencia y velocidad de los modelos de IA generativa en producción.
- Importancia de mantener precisión mientras se reduce el uso de recursos.

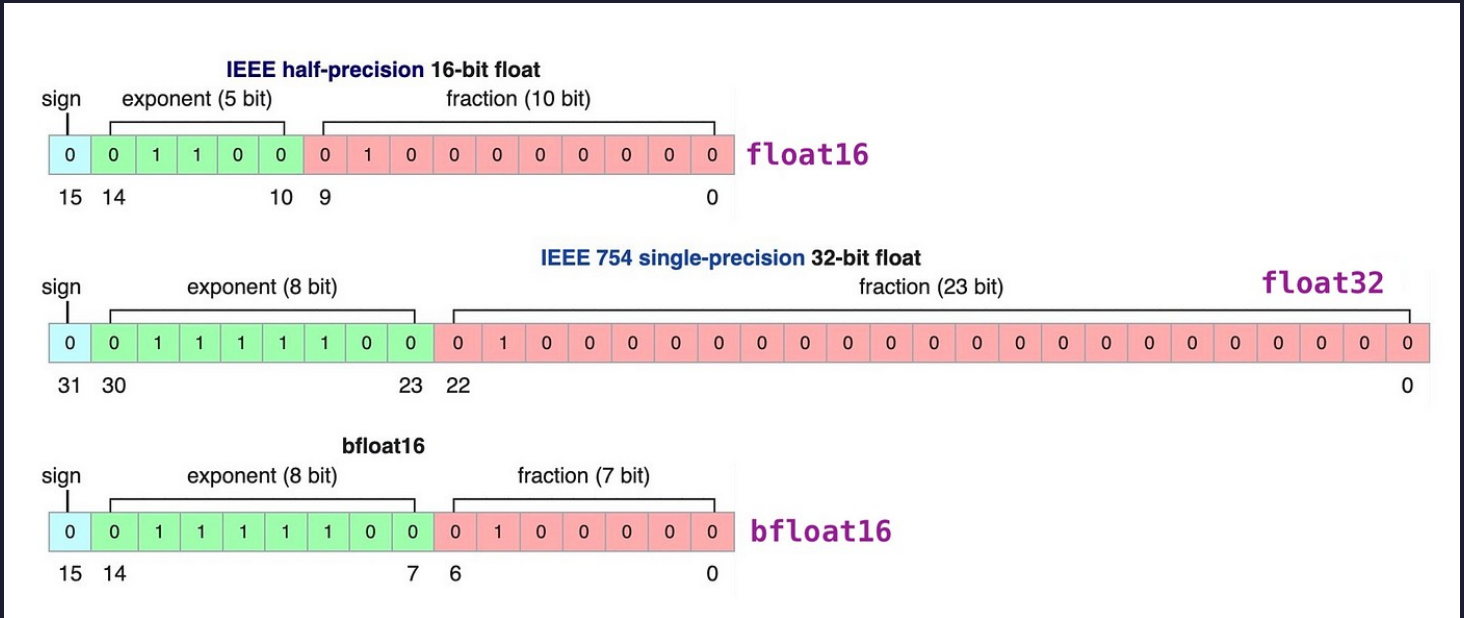


Cuantización

- Reducción de la precisión de los pesos: de FP32 a FP16/BF16, INT8 o 4 bits (NF4, GGUF Q4).
- Disminuye el tamaño del modelo.
- Aumenta la velocidad de inferencia sin pérdida significativa de precisión.



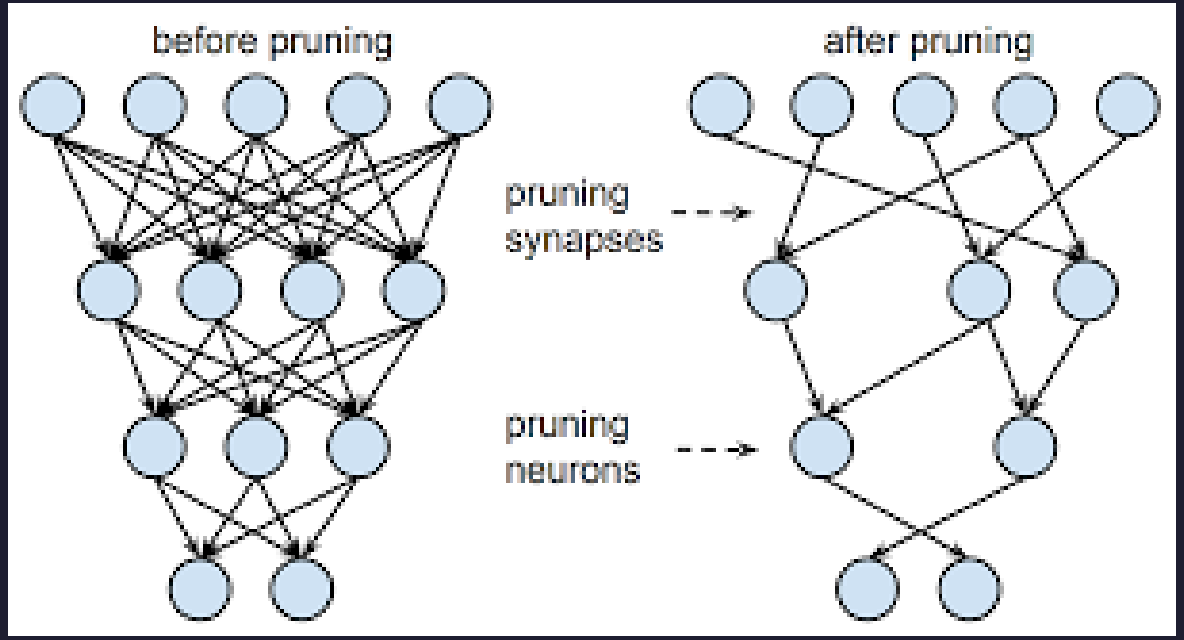
Cuantización



Pruning

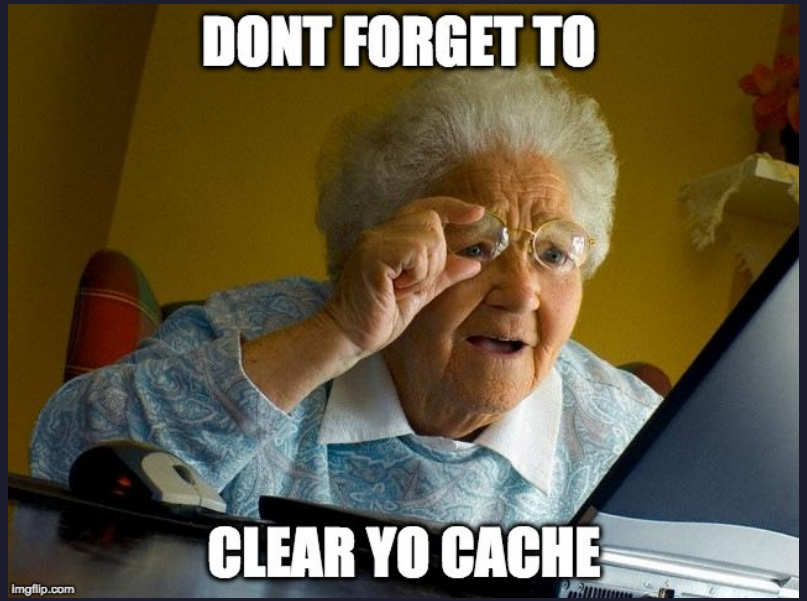
- Eliminación de partes innecesarias del modelo que tienen poco impacto en la salida.
- Reduce la complejidad del modelo.
- Disminuye el tiempo de inferencia y el uso de memoria.

Pruning


before pruning
after pruning
pruning
synapses
pruning
neurons

Caché

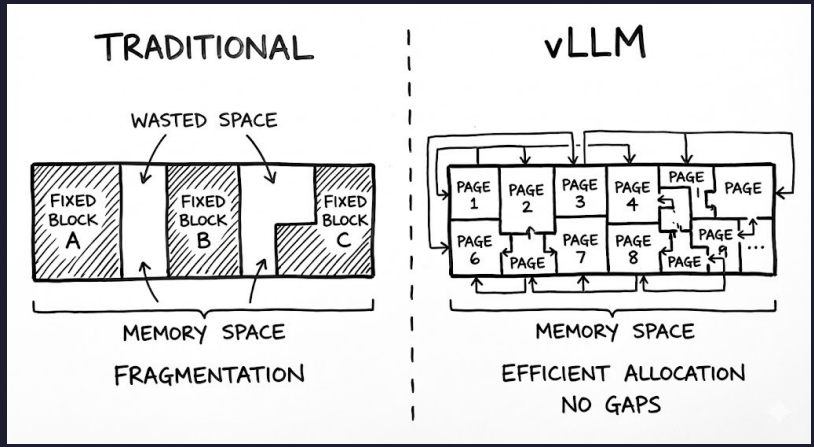
- Implementación de caché para evitar recalcular resultados y procesamiento de múltiples solicitudes en lotes.
- Disminuye la latencia.
- Optimiza el uso de recursos computacionales.



vLLM

- Es un motor de inferencia de código abierto diseñado para maximizar el rendimiento de los LLMs.

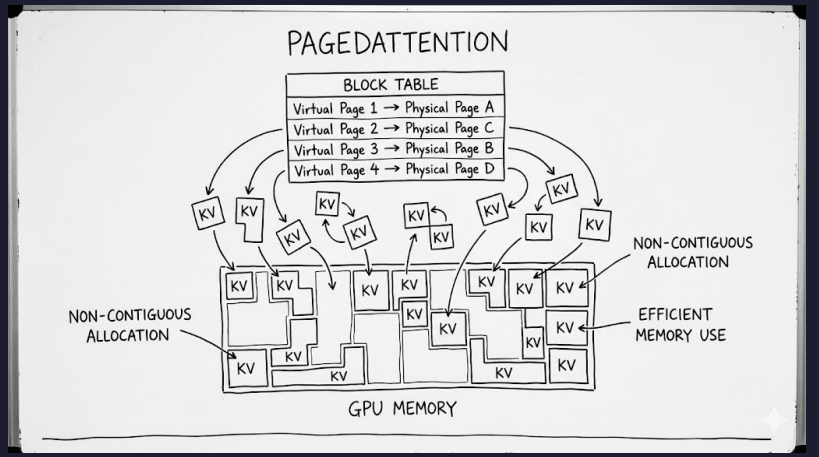
- **Problema que resuelve:**
  Los sistemas tradicionales reservan memoria contigua para la longitud máxima posible de una respuesta, generando "huecos" (fragmentación) y limitando cuántas solicitudes se pueden atender a la vez



vLLM

Algoritmo PagedAttention:

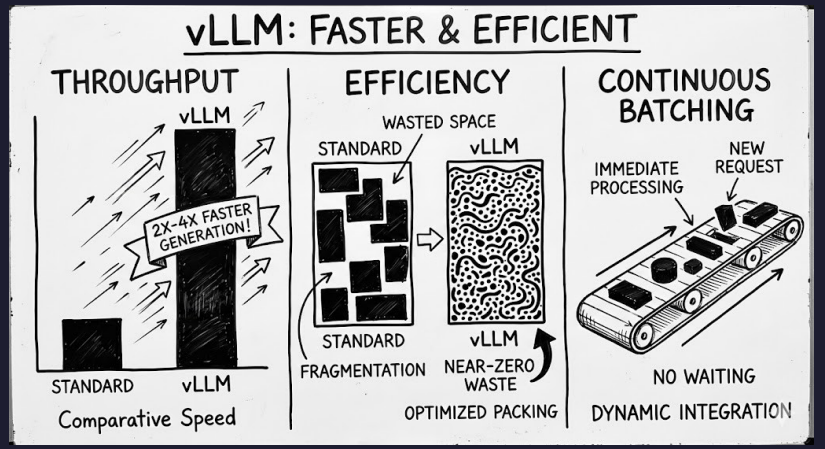
- Inspirado en la memoria virtual de los sistemas operativos.
- Divide el almacenamiento temporal (Caché KV) en bloques pequeños y no contiguos.
- Permite llenar los espacios vacíos de la memoria GPU de manera dinámica, similar a jugar Tetris de forma óptima.



vLLM

Impacto y resultados

- Rendimiento: Aumenta el throughput (tokens/segundo) entre 2x y 4x comparado con sistemas tradicionales como FasterTransformer.
- Eficiencia: Reduce el desperdicio de memoria a casi cero ("near-zero waste").
- Batching Continuo: Procesa nuevas solicitudes inmediatamente sin esperar a que terminen las anteriores.



Despliegue de modelos

- Procesos y prácticas para actualizar y desplegar modelos de IA generativa en producción de manera eficiente y segura.

- Importancia de minimizar el tiempo de inactividad y asegurar la consistencia de los resultados.



Cloud, edge o híbrido

Cloud Deployment

- Utilización de servicios de nube para hospedar y ejecutar modelos.

Edge Deployment

- Ejecutar modelos en dispositivos cercanos al usuario final, como smartphones o dispositivos IoT.

Hybrid Deployment

- Combinación de despliegue en la nube y en el borde.



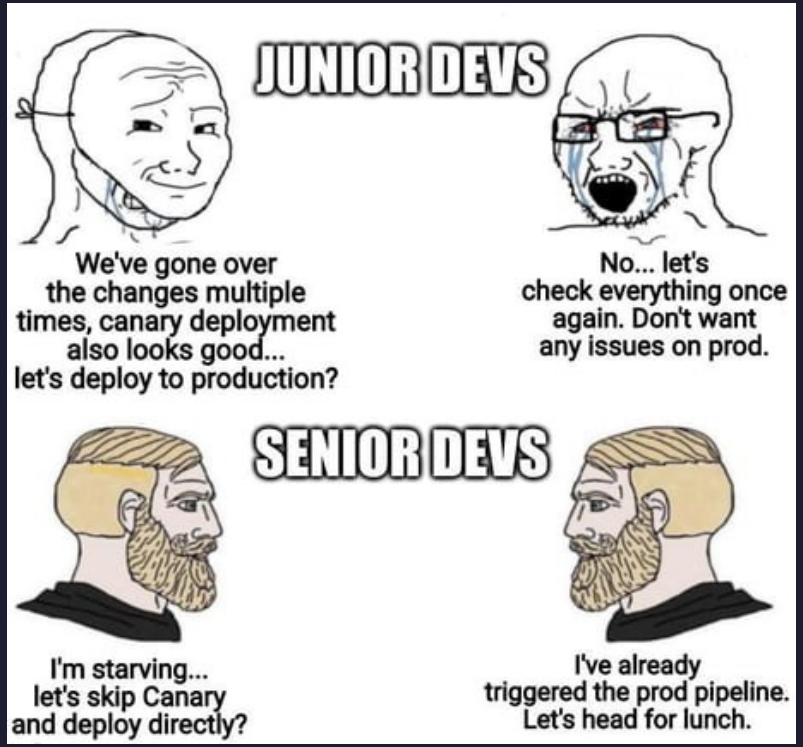
Blue-Green Deployment

- Mantenimiento de dos entornos idénticos (azul y verde) donde uno está activo y el otro en espera.
- Minimiza el tiempo de inactividad.
- Permite pruebas en el entorno de espera antes de cambiar el tráfico al nuevo modelo.



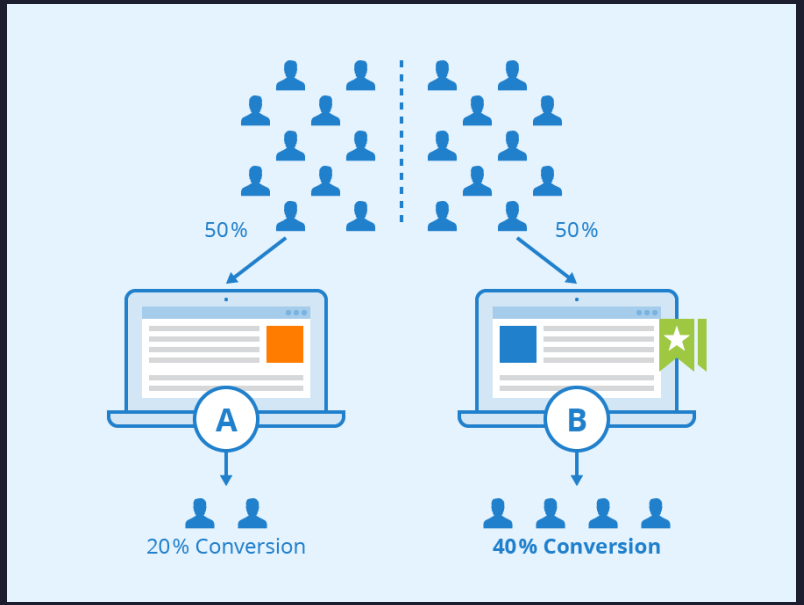
Canary Deployment

- Despliegue gradual del nuevo modelo a un pequeño subconjunto de usuarios antes de lanzarlo completamente.
- Monitoreo y validación en producción con bajo riesgo.
- Permite retroceder rápidamente si se detectan problemas.



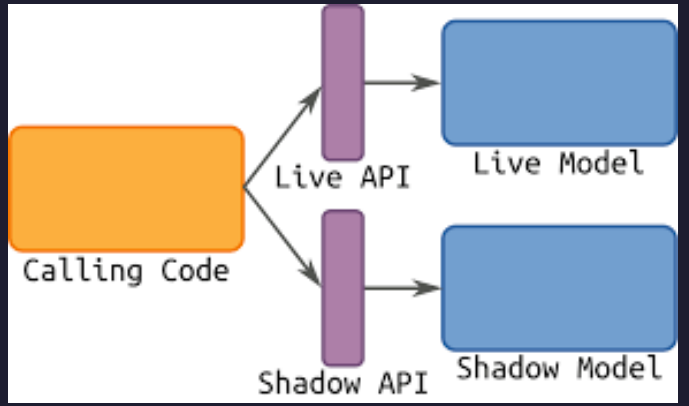
A/B Testing

- Comparación de dos versiones del modelo (A y B) para evaluar su rendimiento y efectividad.
- Identificación clara del mejor modelo basado en datos reales de usuario.
- Facilita la toma de decisiones informadas.



Shadow Deployment

- Ejecución del nuevo modelo en paralelo al modelo en producción, sin impactar al usuario.
- Todas las peticiones se lanzan en ambos modelos y se compara.
- Permite pruebas en un entorno real sin riesgo.
- Comparación directa del rendimiento y comportamiento entre modelos.



API OpenAI

Embeddings

- Representaciones vectoriales de texto que capturan el significado semántico.
- Usos: búsqueda, clustering, recomendaciones.

LLM

- Modelos generativos de texto: gpt-5-mini, GPT-5 y los razonadores GPT-6 (sol, luna, astra).
- Usos: generación de contenido, chatbots, asistentes virtuales.

Multimodal

- Modelos que combinan procesamiento de lenguaje, visión, audio,...
- Usos: descripción de imágenes, generación de contenido visual.

Whisper

- Modelos de transcripción automática de audio a texto.
- Usos: subtitulado automático, transcripción de entrevistas, accesibilidad.

API OpenAI

- Dependencia de Terceros
- Costos Elevados
- Latencia
- Limitaciones de Personalización
- Rate Limits
- Privacidad y Seguridad de Datos
- Regulaciones y Cumplimiento



AWS SageMaker

Real-time + serverless en el stack más usado del sector.

· Real-time inference: endpoints autoscaling + baja latencia · GPUs disponibles

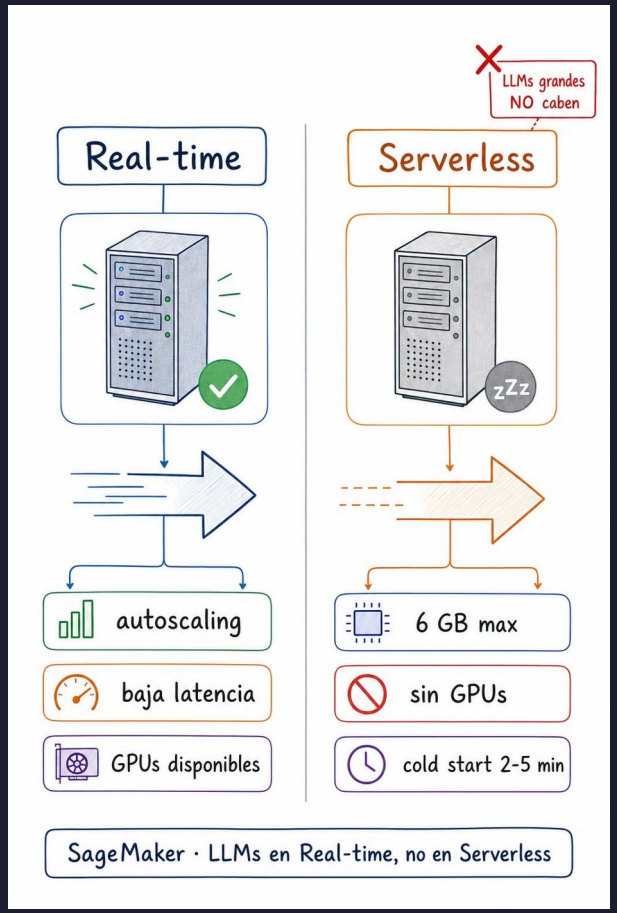
· Serverless inference: scale-to-zero, sin gestionar infra

· Limitación serverless: máx. 6 GB RAM, sin GPUs · LLMs grandes NO caben

· Cold start serverless 2-5 min para LLMs (no apto para latencia crítica)

· JumpStart: catálogo de modelos preentrenados (Llama, Mistral, Stable Diffusion...)

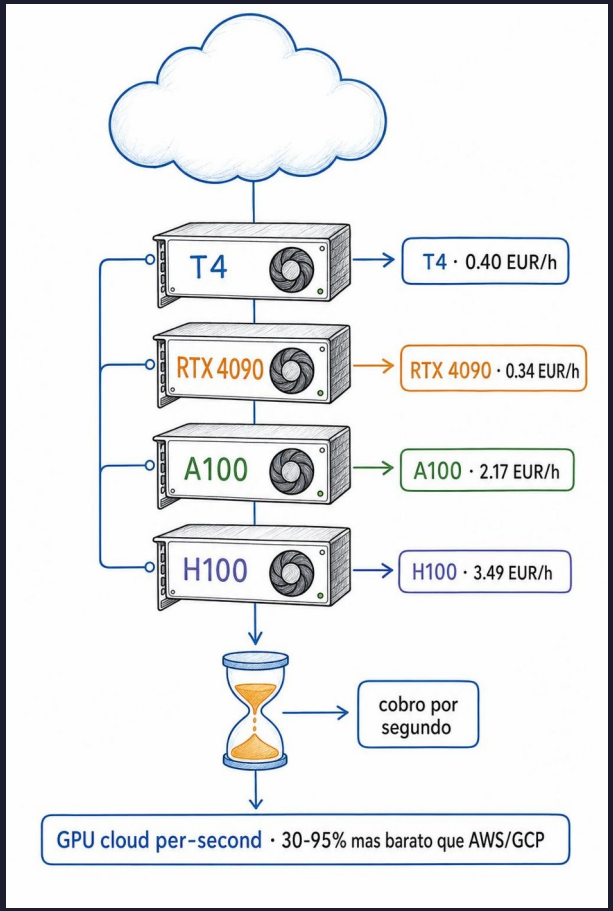
· Para: stack AWS empresarial, compliance, integración con S3/IAM



RunPod

GPU cloud · alquilas pods por horas o pagas serverless por segundo.

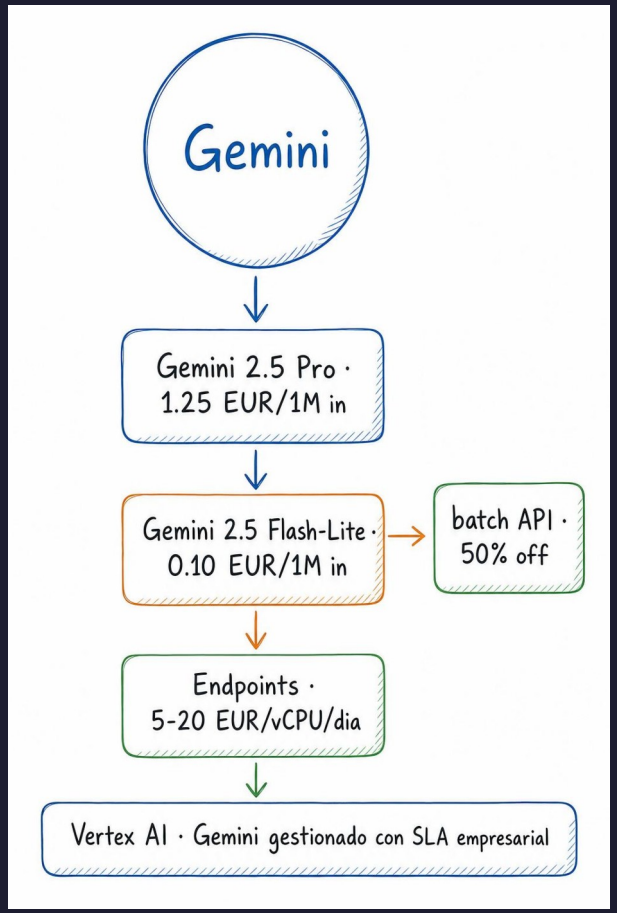
- Pods (USD/h): RTX 4090 desde 0.34, A100 80GB desde 1.19, H100 SXM 2.69-3.49
- Serverless: factura por segundo de worker (no por token) · workers flex o active
- 3 modalidades: Community Cloud (barato), Secure Cloud, Serverless
- Sin cargos de egress, cold starts <200 ms (según RunPod)
- 30-95% más barato que AWS/GCP para inferencia variable (según RunPod)
- Para: training experimental, inferencia esporádica, prototipos



Google Vertex AI

Gemini gestionado · lo que Google Cloud te ofrece para LLMs en 2026.

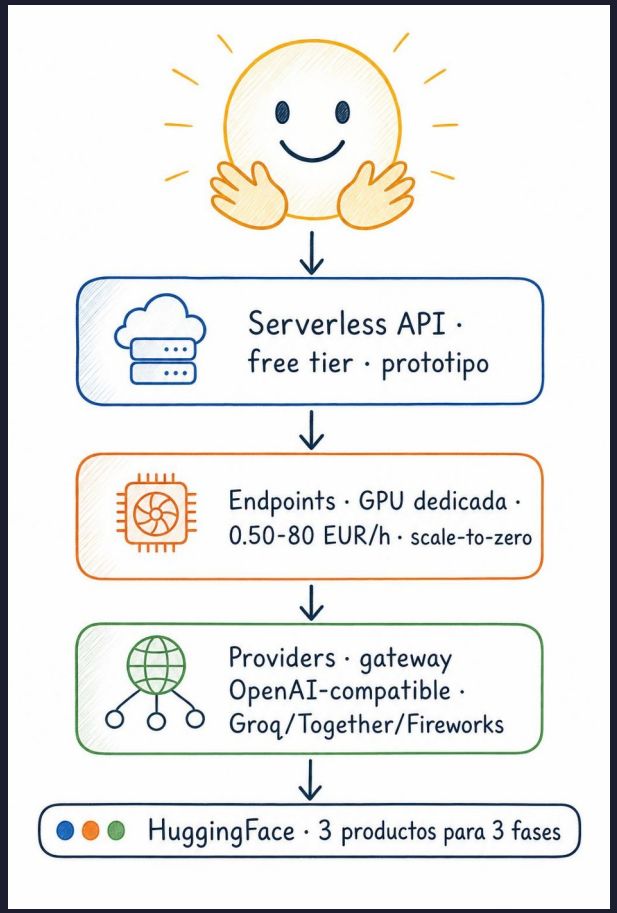
- Modelos Gemini gestionados con SLA empresarial
- Gemini 3.1 Pro (preview): 2.00/12.00 $ por 1M tokens (in/out)
- Gemini 3.1 Flash-Lite: 0.25/1.50 $ · Gemini 2.5 Flash-Lite: 0.10/0.40 $
- Endpoints gestionados: 5-20 EUR/vCPU/día (atención: facturan hasta apagarlos)
- Batch: 50% de descuento en jobs asíncronos
- Para: stack GCP empresarial, Gemini con SLA, compliance regional



HuggingFace

3 productos en 1 · el catálogo natural si vienes del Hub.

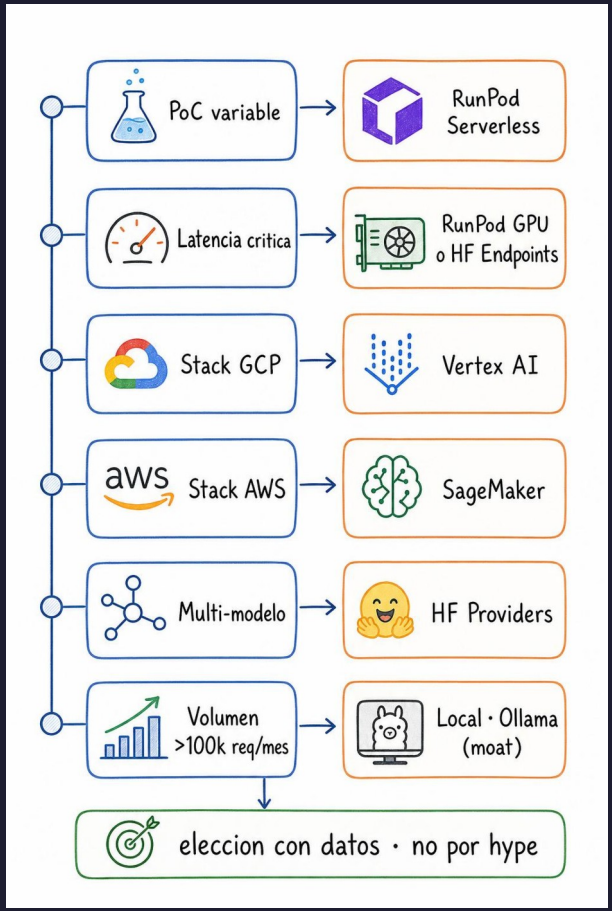
- Inference Providers (antes Serverless Inference API): free tier + créditos PRO
- Inference Endpoints: GPU dedicada · de 0.50 $/h (T4) a 40 $/h (8x H200)
- Endpoints scale-to-zero: no factura mientras está apagado
- Router compatible OpenAI (router.huggingface.co/v1) · Groq, Together, Fireworks, Cerebras...
- Cobro por minuto (aunque el precio se muestre por hora)
- Para: prototipo (Providers) -> producción (Endpoints) -> multimodelo (router)



Matriz cloud providers

Cuándo elegir cada uno · decisión con datos reales 2026.

- PoC rápido + tráfico variable -> RunPod Serverless o HF Inference Providers
- Producción con latencia crítica -> RunPod GPU on-demand o HF Inference Endpoints
- Empresa stack GCP + Gemini -> Vertex AI
- Empresa stack AWS + compliance -> SageMaker Real-time
- Multimodelo con cambio rápido -> router de HF Inference Providers
- Volumen >100k req/mes -> LOCAL (Ollama + Gemma 4 · moat del lab 05 de Fine-tuning)

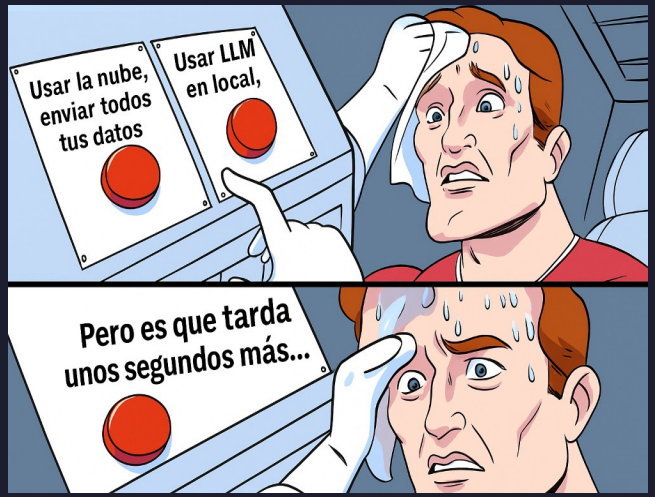


Otros

- https://deepinfra.com/
- https://mistral.ai/
- https://platform.claude.com/
- https://www.together.ai/
- https://openrouter.ai/
- https://huggingface.co/docs/inference-providers
- https://replicate.com/
- …

¿Por qué ejecutar LLMs en local?

- **Privacidad total:** Tus datos permanecen en tu dispositivo, sin necesidad de enviarlos a servidores externos.
- **Autonomía:** No dependes de servicios en la nube ni de conexión a Internet para utilizar modelos de lenguaje.
- **Personalización:** Puedes ajustar y adaptar los modelos a tus necesidades específicas.
- **Reducción de costes:** Evitas suscripciones o tarifas asociadas a servicios en la nube.



Ollama

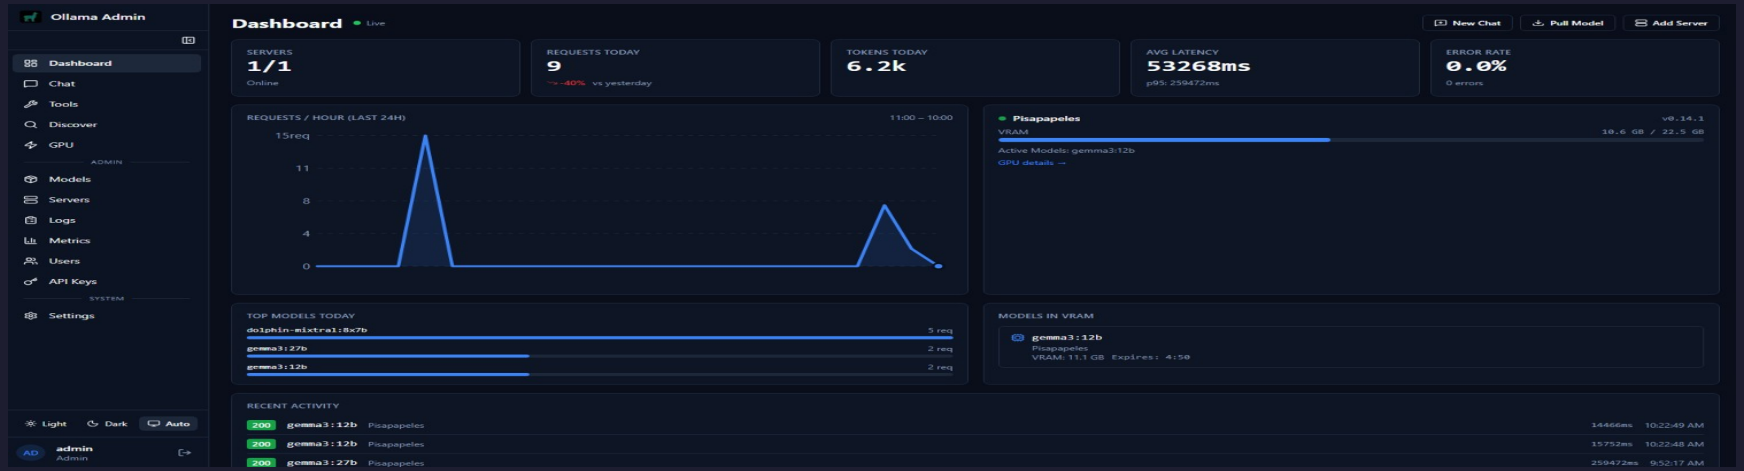
- Open source · macOS, Linux y Windows
- Miles de modelos GGUF: ollama pull gemma4:e4b
- CLI + app de escritorio (macOS/Windows) + SDK
- API local compatible OpenAI · usa GPU si la hay
- Ollama Cloud: modelos grandes con la misma API (ollama.com/v1)



Ollama Admin

keep coding

Admin panel + observabilidad para servir Ollama en serio



- Gateway proxy con logging completo (tokens, latencia, modelo, usuario, IP)
- GPU monitoring multi-vendor (NVIDIA, AMD, Intel, Apple Silicon) en tiempo real
- Multi-server management · varios Ollama desde 1 UI · chat con streaming + comparison
- Auth + RBAC + API keys + rate limiting · install: curl install.sh | bash -> localhost:3000

github.com/ollama-admin/ollama-admin

LM Studio

- App de escritorio
- macOS, Linux y Windows
- Interfaz gráfica intuitiva para interactuar con modelos.
- Modelos GGUF (y MLX en Mac): Gemma 4, Qwen, Mistral, entre otros.
- Funcionalidad de servidor local para integraciones con otras aplicaciones.



Recursos

- https://ollama.com
- https://lmstudio.ai
- https://ollama.com/cloud
- https://docs.vllm.ai


keep coding