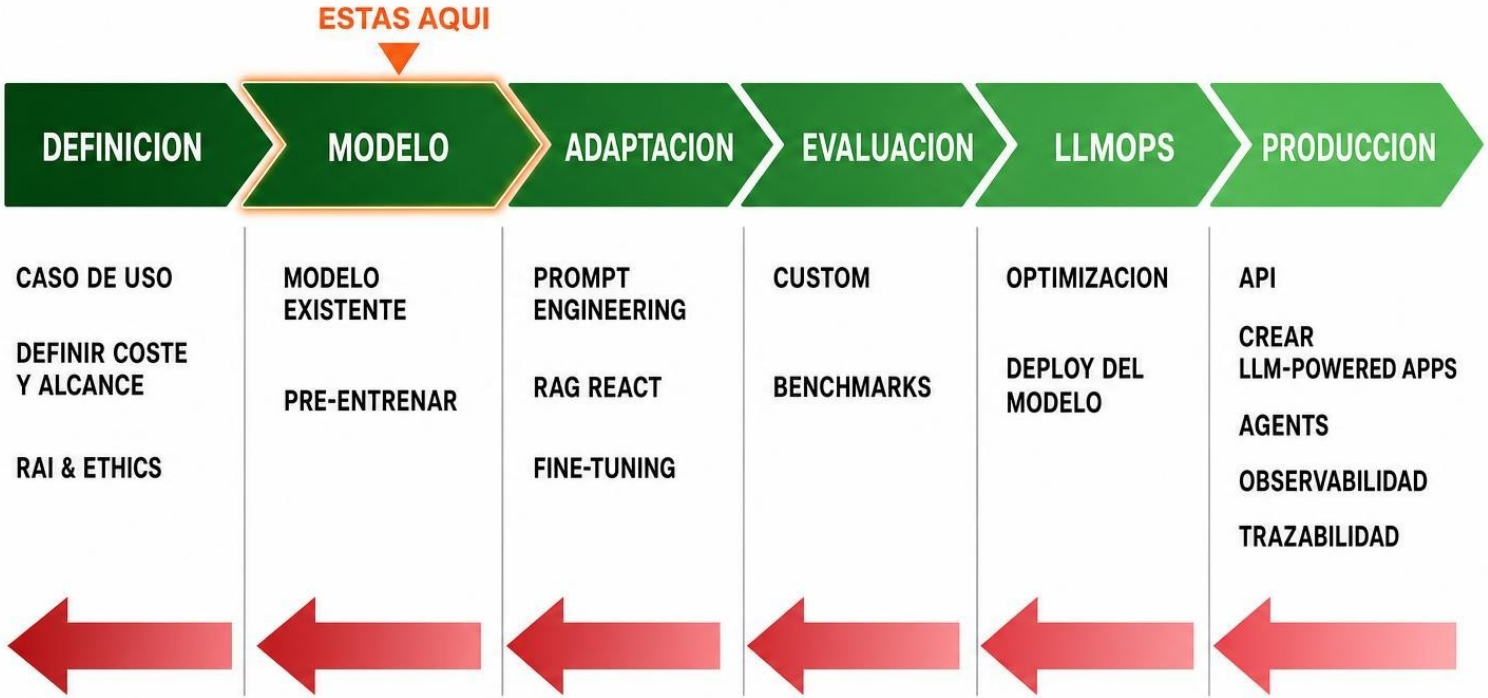
keep coding

AI ENGINEERING

Evaluación de LLMs

GenAI Project Lifecycle



Cómo evaluamos los modelos

keep coding

$$\text{Model Accuracy} = \frac{\text{Correct Predictions}}{\text{Total Predictions}}$$

Cómo evaluamos los modelos

Luke, yo soy tu padre

Luke, yo mate a tu padre



ROUGE

keep coding

Recall-Oriented Understudy for Gisting Evaluation

Evalúa la calidad de los resúmenes generados.

Compara los resúmenes de la máquina con el resumen hecho por un humano.

BLEU

BiLingual Evaluation Understudy

Evalúa la calidad de los textos traducidos por máquinas.

Enfrenta una traducción automática con una traducción de referencia creada por humanos.

Benchmarks

keep coding

- Rouge y Bleu no son suficientes.
- Necesitamos métricas para poder comparar las LLMs y sus capacidades.
- Permiten medir conocimiento, razonamiento, generación de código, etc.
- Clave para saber si un modelo "entiende" o solo repite

¿Qué es la inteligencia?

keep coding

- Para determinar la capacidad de los modelos quizás antes hay que definir qué es inteligencia.
- ¿Resolver problemas? ¿Aprender? ¿Adaptarse? ¿Crear?
- ¿Un test de lógica mide inteligencia o entrenamiento?

Tipos de evaluación en LLMs

keep coding

- 📚 Conocimiento factual (MMLU, TriviaQA)
- 🤔 Razonamiento lógico (GSM8K, ARC)
- 💬 Conversación y diálogo (MT-Bench, Arena)
- 💻 Programación (HumanEval, MBPP, SWEBench)
- 🧠 Multitarea / sentido común (BIG-Bench, HellaSwag)

MMLU

- Massive Multitask Language Understanding
- Evalúa conocimiento en 57 campos académicos
- Formato: Multiple Choice (A, B, C, D)
- Comparado con humanos y estudiantes de secundaria

GSM8K: Grade School Math

keep coding

- Problemas de matemáticas de primaria
- Formato: Preguntas de respuesta abierta
- Evalúa razonamiento paso a paso

ARC

keep coding

- Preguntas de ciencia de nivel escolar
- Requiere inferencia más que conocimiento directo
- Dos versiones: Easy vs Challenge

HellaSwag

keep coding

- Predicción de la siguiente frase más coherente
- Requiere sentido común y comprensión contextual
- Alta dificultad para modelos sin razonamiento

HumanEval

keep coding

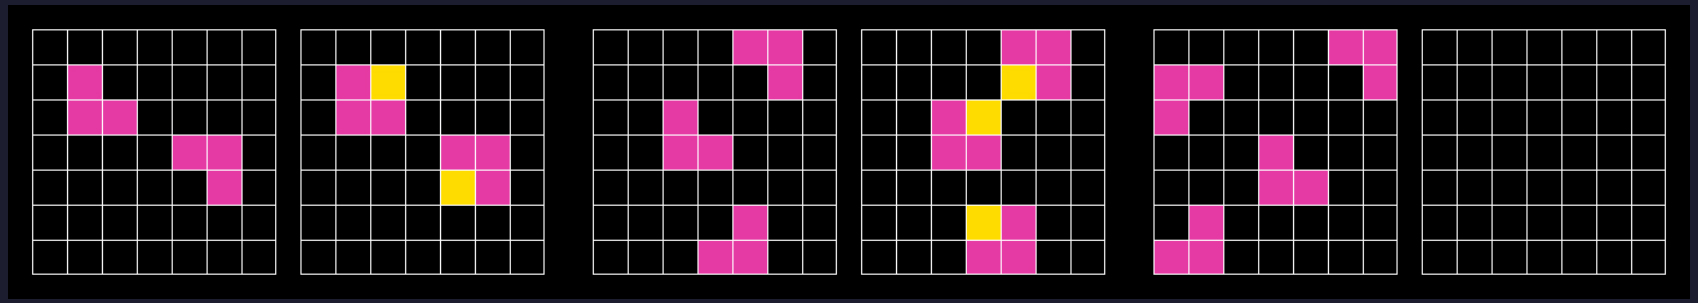
- Escribe funciones en Python dado un enunciado
- Evalúa capacidad de razonamiento + codificación
- Métrica: Pass@1 (¿pasa el test a la primera?)

ARC-AGI

keep coding

- Tarea que un humano puede hacer fácil, pero la IA no.
- Benchmark con test privado: un LLM no puede haber visto esas pruebas en su entrenamiento.
- Aun así, se puede entrenar a un modelo para este tipo de problemas.
- ¿La prueba final para saber si hay AGI? Ya va por ARC-AGI-3 (entornos interactivos).
- https://arcprize.org/arc-agi

ARC-AGI



keep coding

ARC-AGI



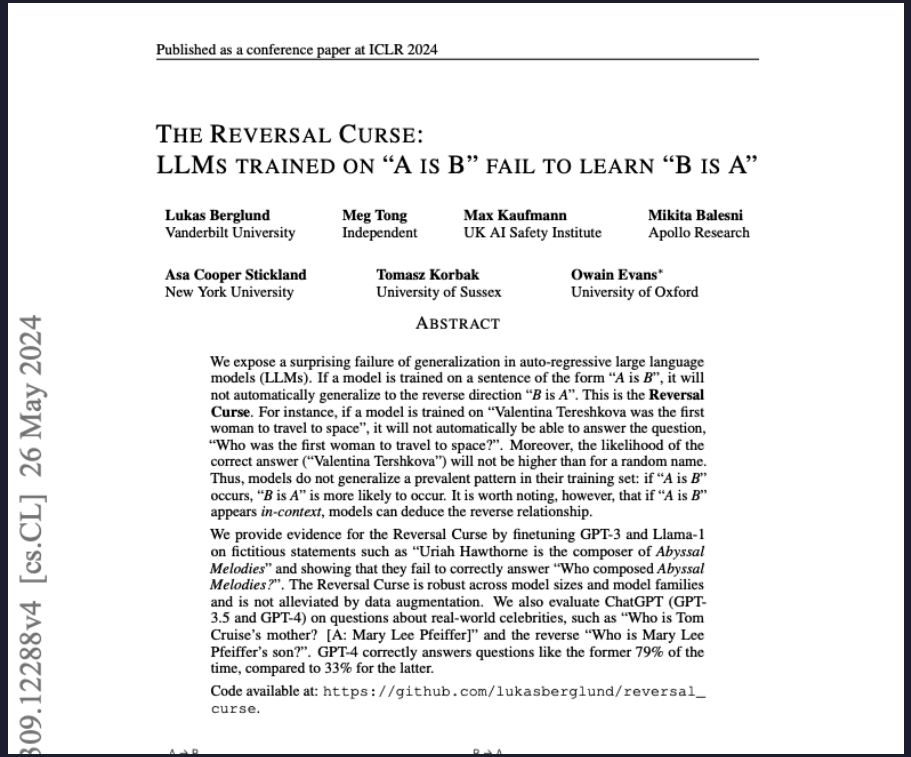
¿Lo estamos haciendo bien?

keep coding

- Si los benchmarks son públicos, ¿de qué sirven?
- Podemos entrenar o fine-tunear un modelo para que saque un 100% en el benchmark.
- Si entrenamos un modelo para aprobar un examen, ¿hay conocimiento real?
- No se deben tomar muy en serio…
- La única salida: que una entidad independiente evalúe los modelos con tests privados.

¿Lo estamos haciendo bien?

keep coding



Published as a conference paper at ICLR 2024

THE REVERSAL CURSE: LLMS TRAINED ON "A IS B" FAIL TO LEARN "B IS A"

Lukas Berglund Vanderbilt University
Meg Tong Independent
Max Kaufmann UK AI Safety Institute
Mikita Balesni Apollo Research
Asa Cooper Stickland New York University
Tomasz Korbak University of Sussex
Owain Evans* University of Oxford

arXiv:2309.12288v4 [cs.CL] 26 May 2024

ABSTRACT

We expose a surprising failure of generalization in auto-regressive large language models (LLMs). If a model is trained on a sentence of the form "*A* is *B*", it will not automatically generalize to the reverse direction "*B* is *A*". This is the **Reversal Curse**. For instance, if a model is trained on "Valentina Tereshkova was the first woman to travel to space", it will not automatically be able to answer the question, "Who was the first woman to travel to space?". Moreover, the likelihood of the correct answer ("Valentina Tershkova") will not be higher than for a random name. Thus, models do not generalize a prevalent pattern in their training set: if "*A* is *B*" occurs, "*B* is *A*" is more likely to occur. It is worth noting, however, that if "*A* is *B*" appears *in-context*, models can deduce the reverse relationship.

We provide evidence for the Reversal Curse by finetuning GPT-3 and Llama-1 on fictitious statements such as "Uriah Hawthorne is the composer of *Abyssal Melodies*" and showing that they fail to correctly answer "Who composed *Abyssal Melodies?*". The Reversal Curse is robust across model sizes and model families and is not alleviated by data augmentation. We also evaluate ChatGPT (GPT-3.5 and GPT-4) on questions about real-world celebrities, such as "Who is Tom Cruise's mother? [A: Mary Lee Pfeiffer]" and the reverse "Who is Mary Lee Pfeiffer's son?". GPT-4 correctly answers questions like the former 79% of the time, compared to 33% for the latter.

Code available at: `https://github.com/lukasberglund/reversal_curse`.

A→B B→A

Frontier vs local · octubre 2026

Los clásicos (MMLU, HumanEval) están saturados: hoy se mira MMLU-Pro, GPQA o HLE.

- Frontier · MMLU-Pro ~0.90 (techo actual: Gemini 3 Pro y Claude Opus 4.5)
- SWE-bench Verified · OpenAI dejó de reportarlo (feb-2026) · ahora SWE-bench Pro
- Gemma 4 E4B (local) · MMLU-Pro 0.694 · GPQA Diamond 0.586 · cabe en T4
- Qwen3-4B base vs instruct (notebook 01) · tu MMLU-ML medido en clase
- Gap frontier vs local 4B · ~20 puntos de MMLU-Pro · el lab 05 de Fine-tuning (distillation) lo estrecha en TU dominio

Evaluación de modelos

- ¿Y si utilizamos un LLM para evaluar el trabajo que hace otro?
- ¿Necesita ser un modelo grande? ¿Puede ser un modelo finetuned?
- ¿Evaluamos cada posible entrada y salida de nuestro sistema?
- ¿Evaluamos nuestro sistema de forma automática cada cierto tiempo?

LMArena (antes Chatbot Arena)

keep coding

LMSYS Chatbot Arena Leaderboard

| Vote | Blog | GitHub | Paper | Dataset | Twitter | Discord |

LMSYS Chatbot Arena is a crowdsourced open platform for LLM evals. We've collected over **300,000** human preference votes to rank LLMs with the Elo ranking system.

Arena Elo | Full Leaderboard

Total #models: **73**. Total #votes: **374418**. Last updated: March 7, 2024.

Contribute your vote at chat.lmsys.org! Find more analysis in the notebook.

Rank	Model	Arena Elo	95% CI	Votes	Organization	License	Knowledge Cutoff
1	GPT-4-1106-preview	1251	+5/-5	45291	OpenAI	Proprietary	2023/4
2	GPT-4-0125-preview	1251	+6/-6	15251	OpenAI	Proprietary	2023/12
3	Claude 3 Opus	1233	+9/-7	5246	Anthropic	Proprietary	2023/8
4	Bard (Gemini Pro)	1203	+6/-8	12623	Google	Proprietary	Online
5	GPT-4-0314	1185	+5/-5	24689	OpenAI	Proprietary	2021/9
6	Claude 3 Sonnet	1180	+10/-8	5259	Anthropic	Proprietary	2023/8
7	GPT-4-0613	1161	+5/-5	39845	OpenAI	Proprietary	2021/9
8	Mistral-Large-2402	1155	+6/-6	9746	Mistral	Proprietary	Unknown
9	Mistral Medium	1147	+5/-4	22171	Mistral	Proprietary	Unknown
10	Qwen1.5-72B-Chat	1147	+4/-5	15288	Alibaba	Qianwen LICENSE	2024/2
11	Claude-1	1146	+5/-6	20833	Anthropic	Proprietary	Unknown
12	Claude-2.0	1127	+6/-5	13679	Anthropic	Proprietary	Unknown
13	Mistral-Next	1124	+5/-6	11875	Mistral	Proprietary	Unknown
14	Gemini Pro (Dev API)	1118	+6/-7	11496	Google	Proprietary	2023/4
15	Claude-2.1	1116	+4/-5	31815	Anthropic	Proprietary	Unknown



Leaderboards

- Open LLM Leaderboard (HF): v1 archivado jun-2024 · v2 retirado en 2025 (solo histórico)
- https://lmarena.ai
- https://artificialanalysis.ai
- https://arcprize.org/leaderboard

Notebook 01 · base vs instruct

keep coding

Hands-on con lm-evaluation-harness · Qwen3-4B en T4 (4-bit).

- Carga Qwen/Qwen3-4B-Base en 4-bit NF4 (selector big: Qwen3-14B en A100/H100)
- Evalúa HellaSwag, ARC-Easy y MMLU-ML (5-shot, 0-shot, CoT)
- Libera memoria y carga Qwen/Qwen3-4B (post-entrenado, instruct)
- Misma batería de evaluaciones
- Cierra con tabla comparativa: delta base vs instruct en cada benchmark
- Receta para repetirlo con tus adapters de Fine-tuning (labs 04 y 05)

LLM Autoeval

keep coding

- https://github.com/mlabonne/llm-autoeval
- https://github.com/huggingface/lighteval

Benchmarks vigentes en 2026

keep coding

Los clásicos (MMLU, HumanEval, ARC-AGI-1) están saturados a >90% en frontier.

- MMLU-Pro · 10 opciones + CoT · sustituye a MMLU · frontier ~90%
- GPQA Diamond · 198 preguntas de nivel doctorado (biología, física, química)
- SWE-bench Pro · coding real · sustituye a Verified (contaminado, feb-2026)
- Humanity's Last Exam · 2.500 preguntas expertas · frontier 55-61% (sept-2026)
- LiveCodeBench · problemas de concursos nuevos · anti-leakage
- ARC-AGI-2 · razonamiento puro · Gemini 3 Deep Think 84.6% (feb-2026) · ya hay ARC-AGI-3

Matriz local vs API

La decisión que aterriza LLMOps + Fine-tuning + Evaluación.

- API (GPT-5, gpt-6-sol, Claude Opus 4.7) GANA en: PoC rápido, multimodal de frontera, calidad máxima
- Local (Gemma 4 E4B + Ollama) GANA en: volumen alto, datos sensibles, sin conexión, coste fijo
- Orden de magnitud · ~2000 EUR/mes en API con 100k req vs ~20 EUR/mes en local (electricidad)
- Benchmarks · frontier ~90% MMLU-Pro · Gemma 4 E4B 69.4% · ~100x menos coste justifica caer ~20 puntos
- Regla práctica · empieza en API, baja a local si el caso es estable y de volumen
- El lab 05 de Fine-tuning (distillation) te enseña a cerrar el gap de calidad en TU dominio específico

Evaluación · MODELO vs APP

Por qué evaluamos dos veces y qué mide cada módulo.

· Aquí (clase 3) · evalúa el MODELO · benchmarks públicos (MMLU-Pro, GPQA, HellaSwag) · 1 número global

· Evaluación de LLM apps (clase 6) · evalúa tu APP · LLM-as-judge, A/B test, regresión en CI · 1 número por feature/caso

· Aquí ves si el modelo tiene la capacidad · en clase 6, si tu producto la usa bien

· Ambos son necesarios · aquí validas la elección del modelo base · en clase 6, la integración (prompt + RAG + flow)

· Si el benchmark dice 'el modelo es bueno' pero tu app 'responde mal' · falla el prompt o el RAG, no el modelo


keep coding