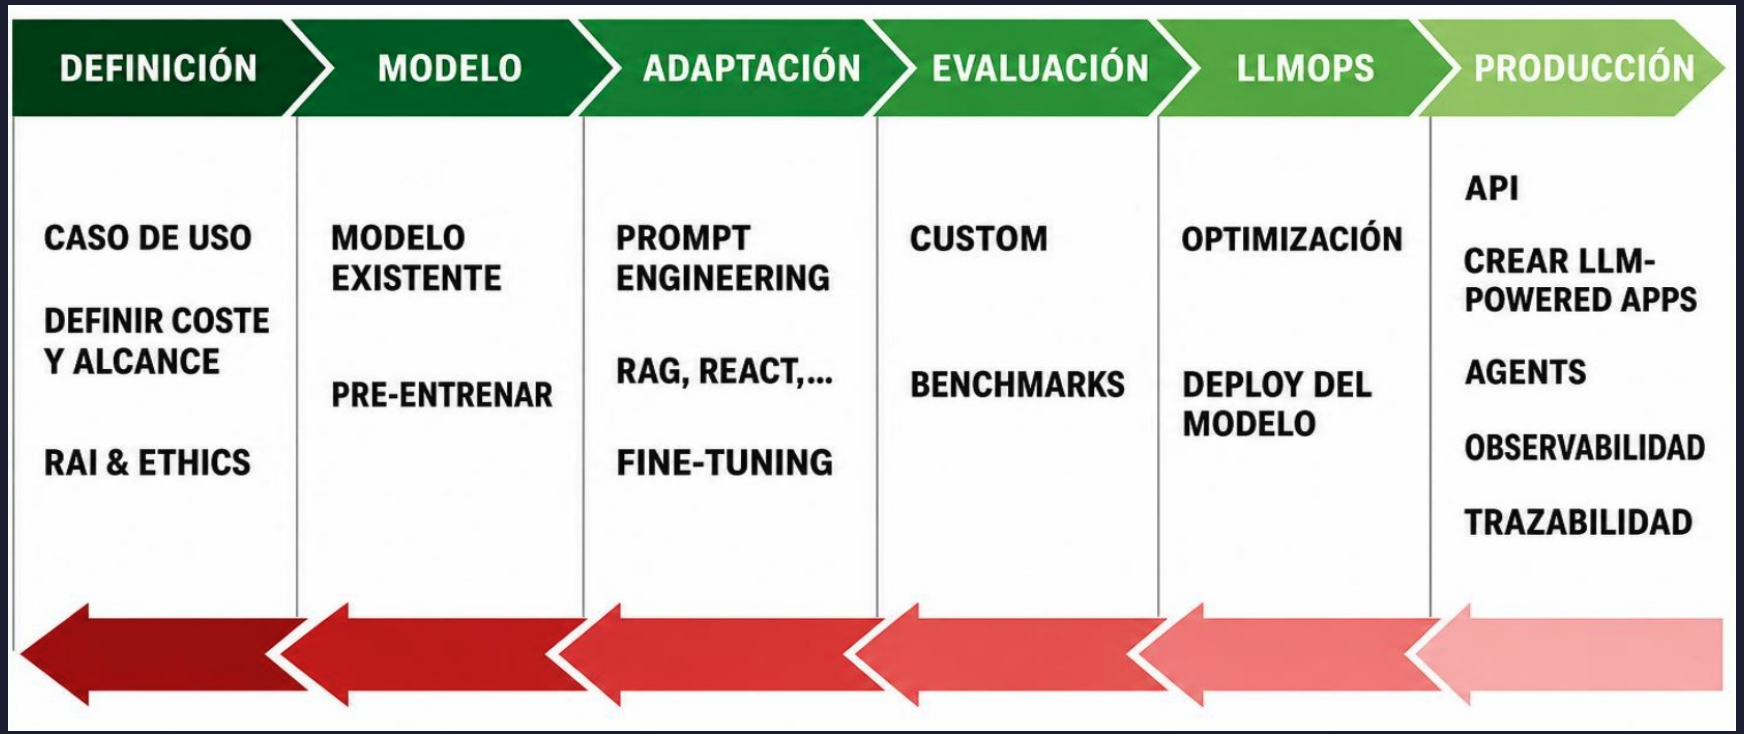
keep coding

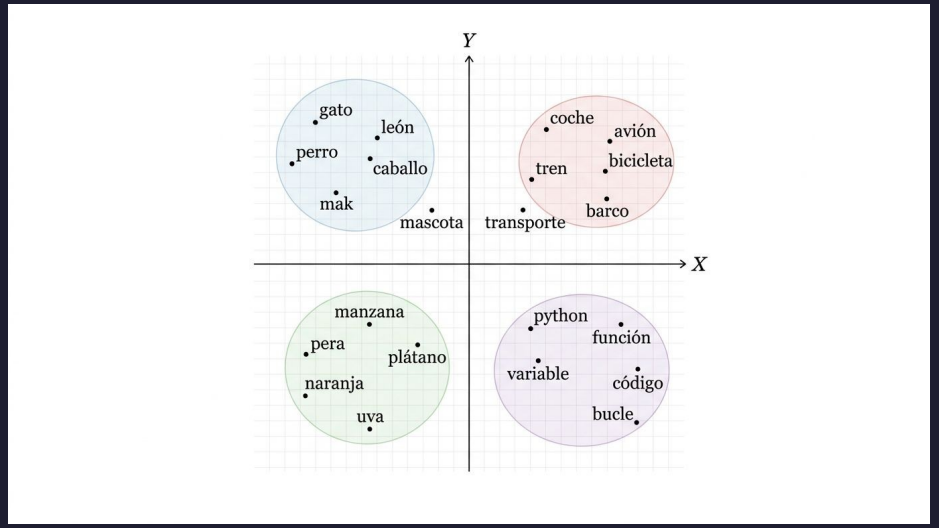
AI ENGINEERING

Embeddings y Vectorstores


DEFINICIÓN
MODELO
ADAPTACIÓN
EVALUACIÓN
LLMOPS
PRODUCCIÓN
CASO DE USO
DEFINIR COSTE Y ALCANCE
RAI & ETHICS
MODELO EXISTENTE
PRE-ENTRENAR
PROMPT ENGINEERING
RAG, REACT,...
FINE-TUNING
CUSTOM
BENCHMARKS
OPTIMIZACIÓN
DEPLOY DEL MODELO
API
CREAR LLM-POWERED APPS
AGENTS
OBSERVABILIDAD
TRAZABILIDAD

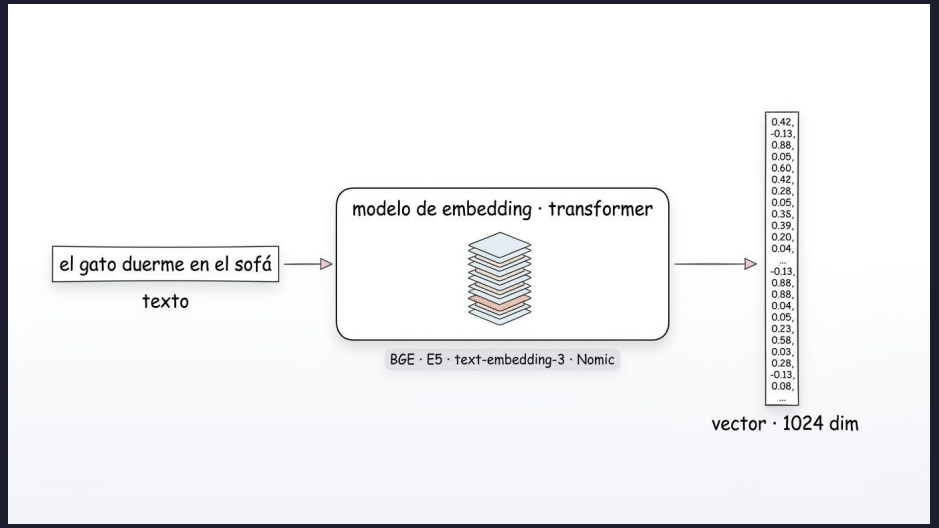
¿Qué es un embedding?

- Vector que representa el "significado" de un texto
- Cada dimensión captura un rasgo semántico latente
- Textos similares · vectores cercanos en el espacio
- Pieza base sobre la que se construye RAG



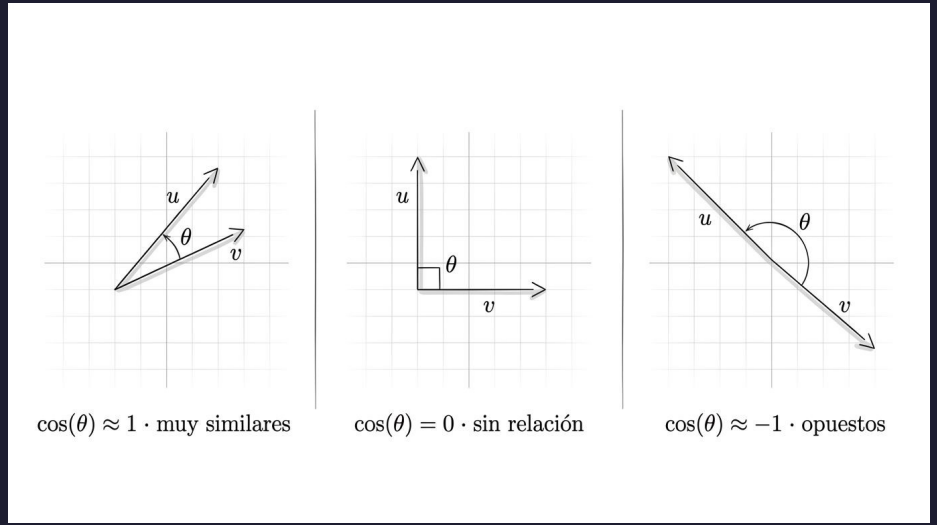
Cómo se calculan

- Un modelo de embedding lee texto y devuelve un vector
- Open : BGE-M3 · E5 · Nomic · Jina · Qwen3-Embedding
- Cerrados : text-embedding-3 · voyage-4 · Cohere embed-v4.0
- Dimensión típica : 384 a 3072
- Cambiar de modelo obliga a re-embeber todo el corpus



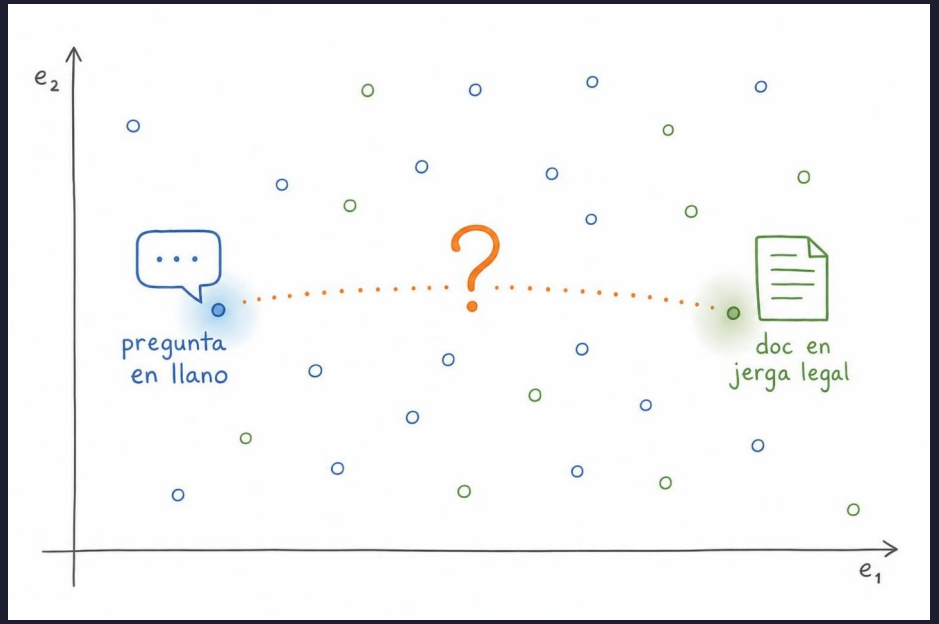
Similitud coseno

- Mide el ángulo entre vectores: dirección, no longitud
- 1 = misma dirección · 0 = sin relación · -1 = opuestos
- Métrica de facto para retrieval
- Con vectores normalizados: coseno = producto escalar
- Y da el mismo ranking que la distancia euclídea



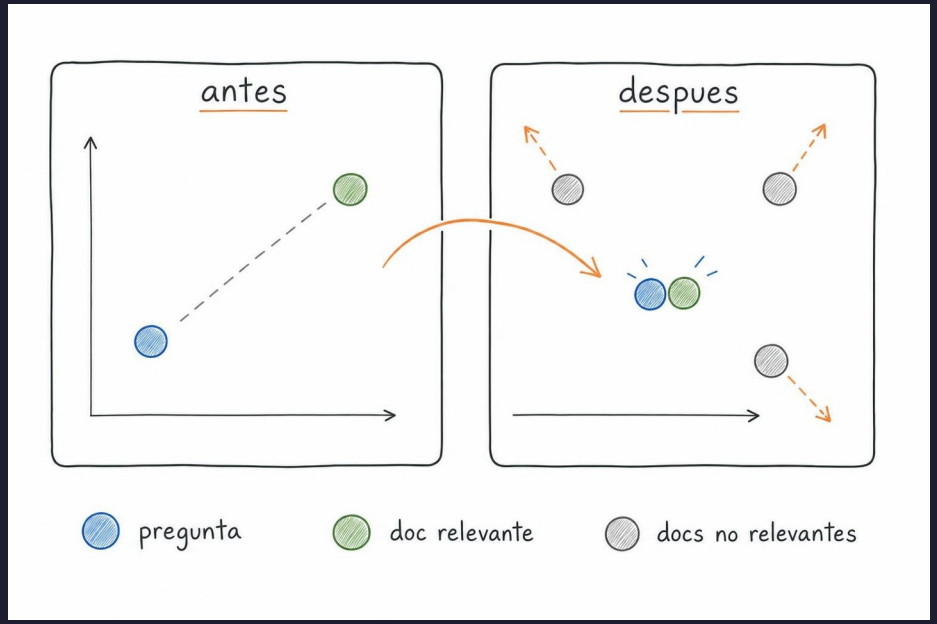
Afinar el embedding al dominio

- El usuario pregunta en llano: '¿pueden echarme del piso?'
- El documento está en jerga: 'resolución del arrendamiento, desahucio...'
- El embedding genérico no los acerca en el espacio vectorial
- En dominios cerrados (legal, médico, código) el hueco es enorme



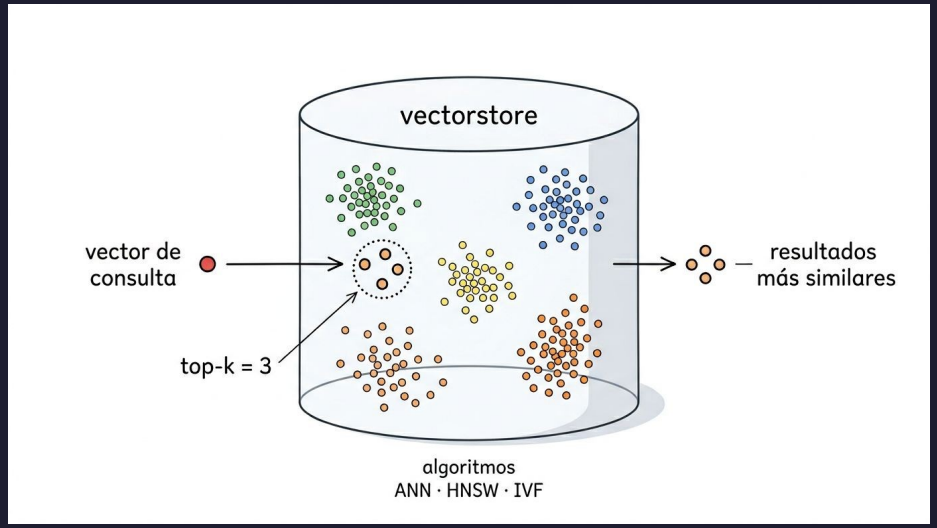
Fine-tuning contrastivo

- Entrenas con pares (pregunta, documento relevante)
- Contrastive learning: acerca el positivo, aleja los negativos
- MultipleNegativesRankingLoss: el resto del batch son negativos
- Pocos pares y minutos: sube top-1 / MRR y mejora el RAG
- Lab 04 · Fine-tuning de embeddings (legal)



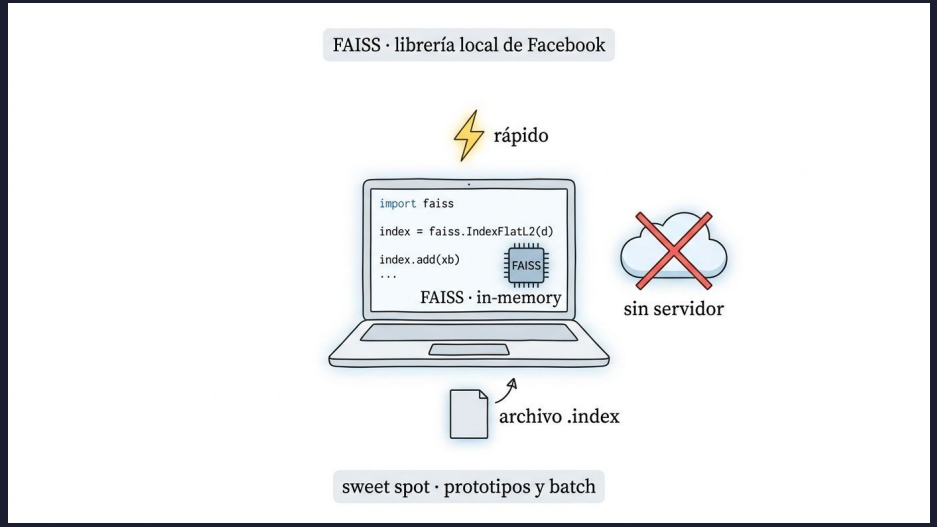
¿Qué es un vectorstore?

- Base de datos optimizada para búsqueda por similitud
- Indexa millones de vectores · top-k en milisegundos
- Algoritmos ANN : HNSW · IVF · ScaNN
- Filtros por metadata (autor, fecha, idioma...)



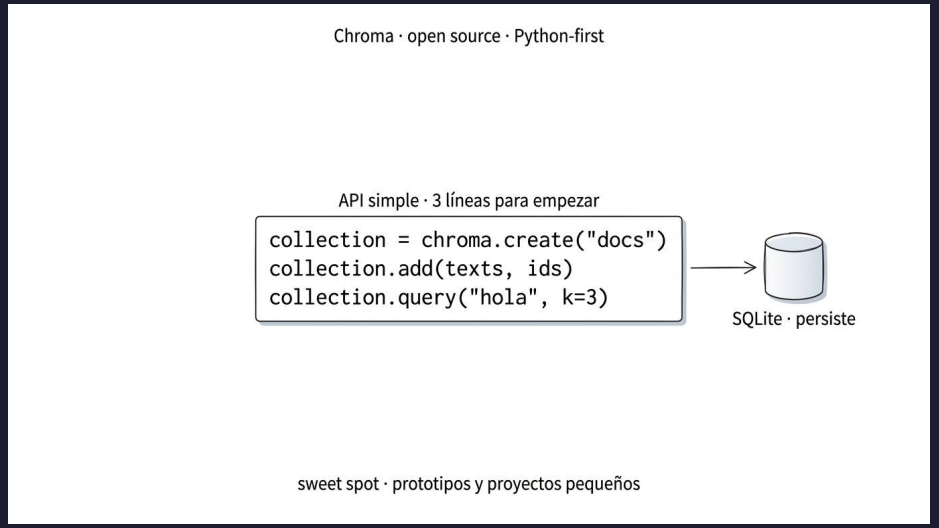
FAISS

- Facebook AI Similarity Search (Meta) · 2017 · C++ con bindings Python
- Local · in-process · muy rápida
- Sin servidor · el índice vive en tu proceso
- Persistencia manual · write_index() / save_local()
- Sweet spot : prototipos, batch, RAM



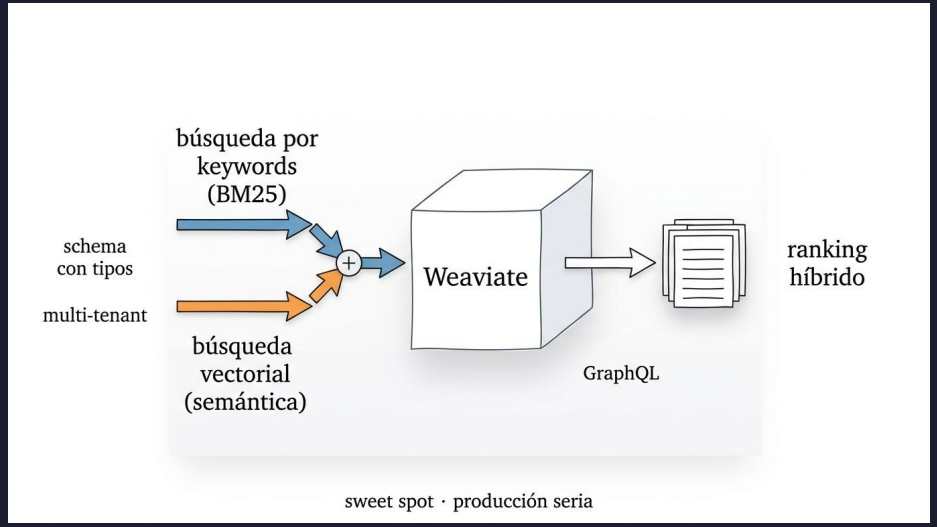
Chroma

- Open source · Python-first · 2023
- Persiste en SQLite o cliente/servidor
- API simple : collection.add() · collection.query()
- Sweet spot : prototipos y proyectos pequeños/medianos



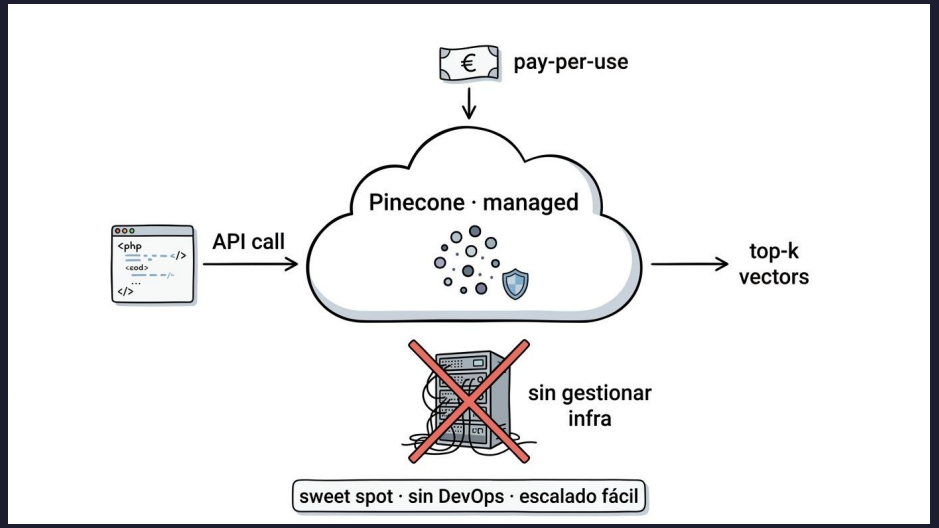
Weaviate

- Open source · escala a millones de vectores
- Schema con tipos y relaciones
- Búsqueda híbrida (keyword + vector) nativa
- Multi-tenancy · GraphQL · self-hosted o cloud
- Sweet spot : producción seria



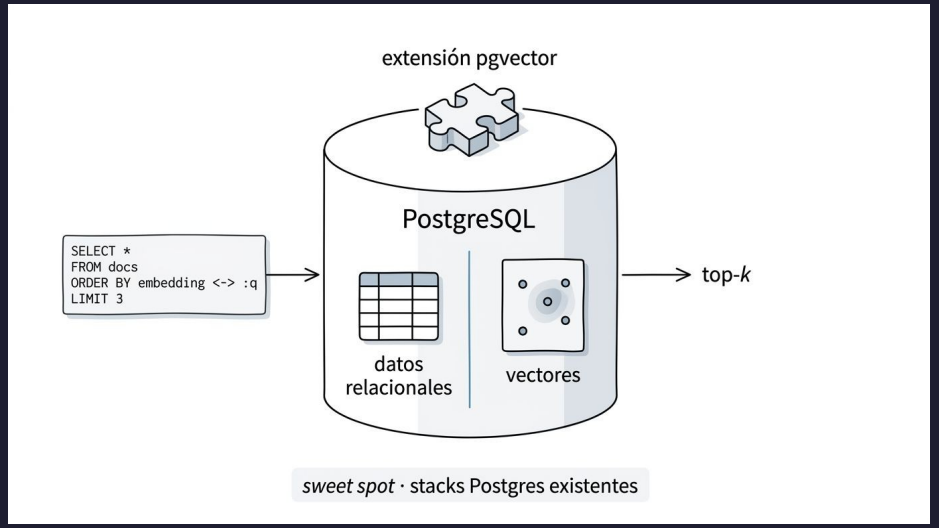
Pinecone

- Managed · serverless · pay-per-use · 2019
- Sin gestión de infraestructura
- Filtros y namespaces multi-tenant
- Integraciones con todo el ecosistema
- Sweet spot : equipos sin DevOps



pgvector

- Extensión de PostgreSQL · 2021
- Vectores y búsqueda dentro de tu Postgres
- Sin DB nueva · aprovechas lo que ya tienes
- HNSW · IVFFlat · híbrido con SQL
- Sweet spot : stacks Postgres existentes



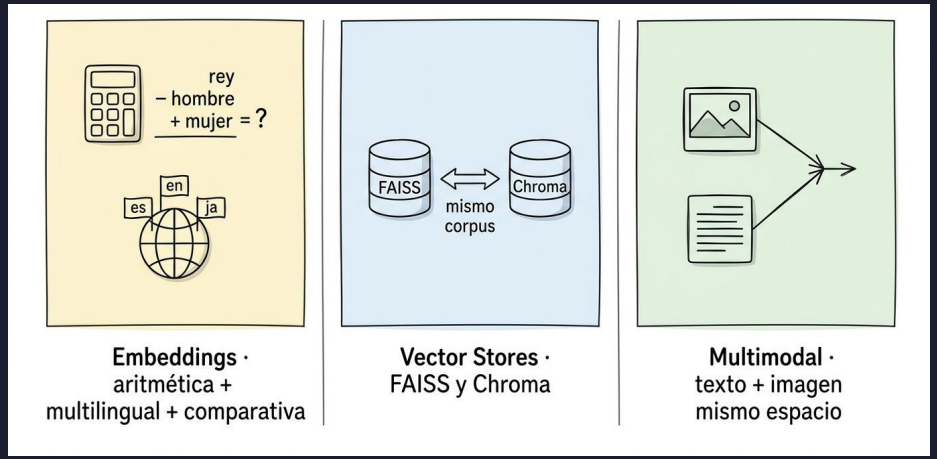
Matriz de decisión

- Local · FAISS para prototipos rápidos
- Self-hosted · Weaviate o Qdrant para control total
- Managed · Pinecone si no quieres DevOps
- Híbrido SQL · pgvector si ya tienes Postgres
- Criterios : coste · latencia · escala · filtros

	FAISS	Chroma	Weaviate	Pinecone	pgvector
Coste	gratis ★★★	gratis ★★★	self-host ★★	managed ★	ya pagado ★★★
Latencia	in-memory ★★★	rápida ★★	buena ★★	alta ★★★	aceptable ★★
Escala	limitada ★	media ★★	alta ★★★	alta ★★★	media ★★
Filtros metadata	limitados ★	sí ★★	complejos ★★★	potentes ★★★	SQL ★★★
Facilidad de Uso	Baja ★	Media ★★	Alta ★★★	Muy Alta ★★★	Media ★★

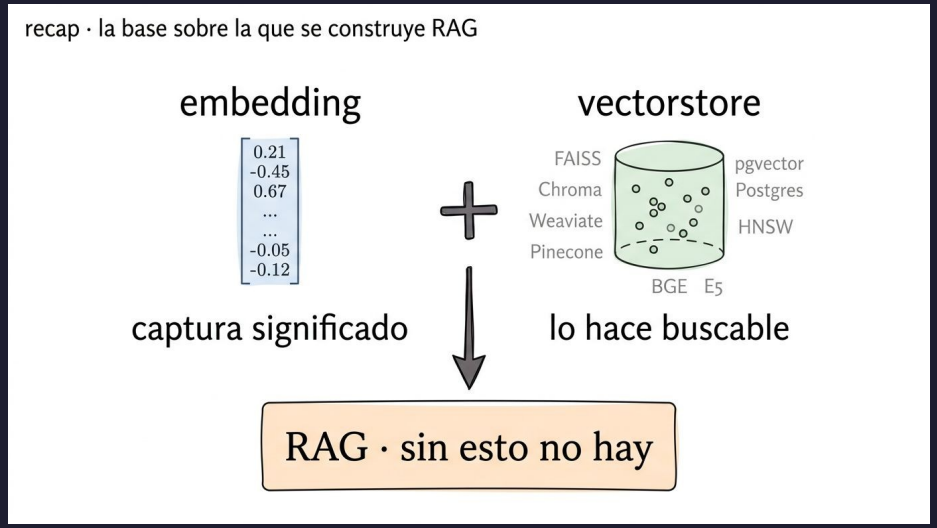
LAB · 4 notebooks

- 01 Embeddings · aritmética · multilingüe · OpenAI/Cohere/BGE-M3
- 02 Multimodal · Cohere embed-v4.0 · texto + imagen
- 03 Vector Stores · FAISS y Chroma con el mismo corpus
- 04 Fine-tuning de embeddings · dominio legal · MRR
- Chunking, PDFs y metadata: en el módulo de RAG



Recap

- Embedding captura significado · vectorstore lo hace buscable
- Cambiar de modelo de embedding obliga a re-indexar
- FAISS local · Chroma simple · Weaviate/Pinecone producción
- pgvector si ya tienes Postgres
- Siguiente módulo: RAG · sin esto, no hay RAG




keep coding