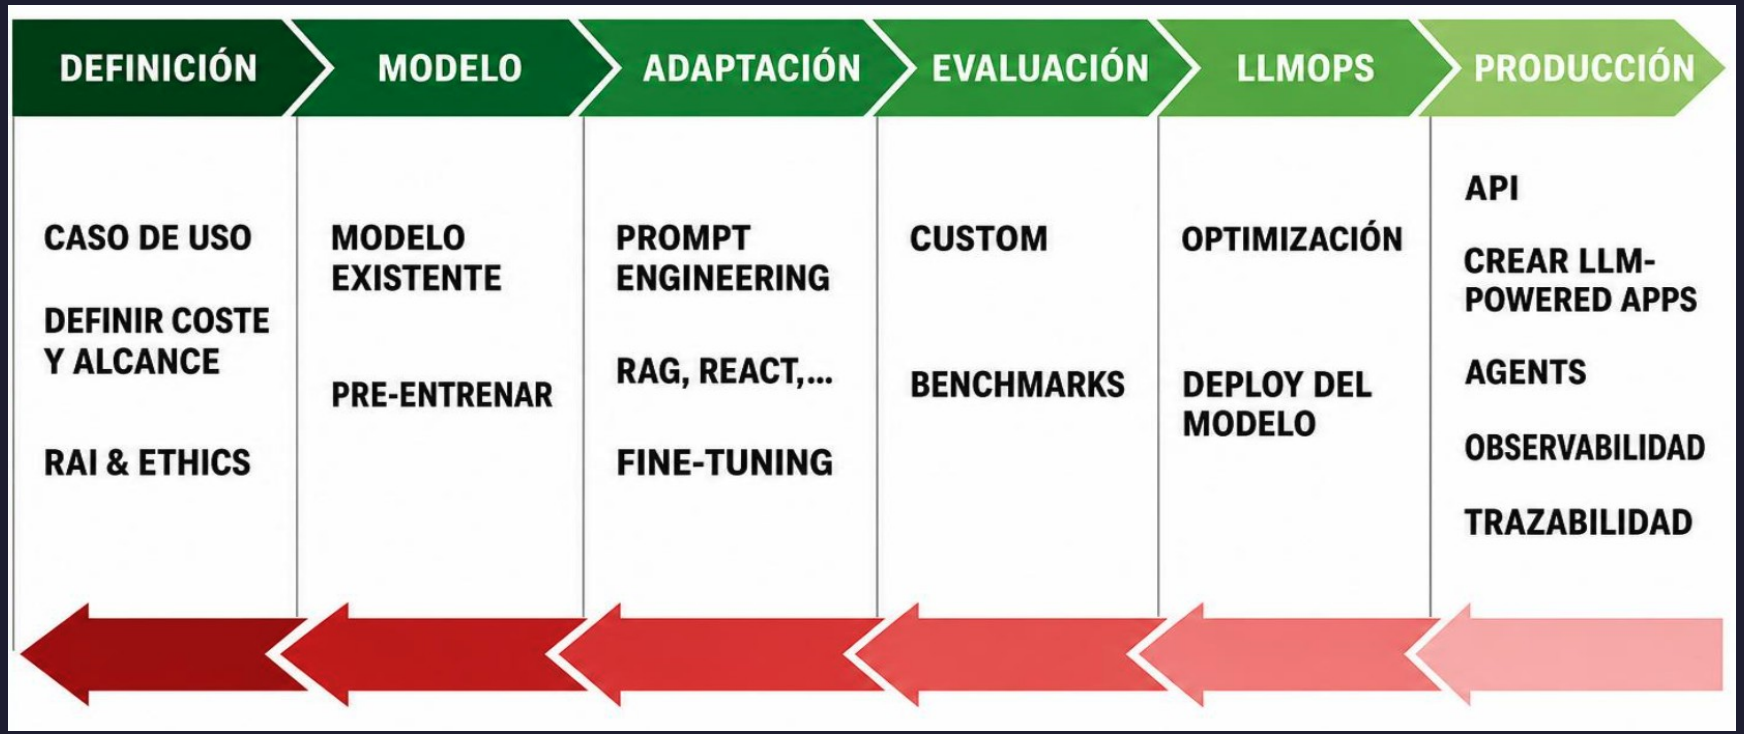
keep coding

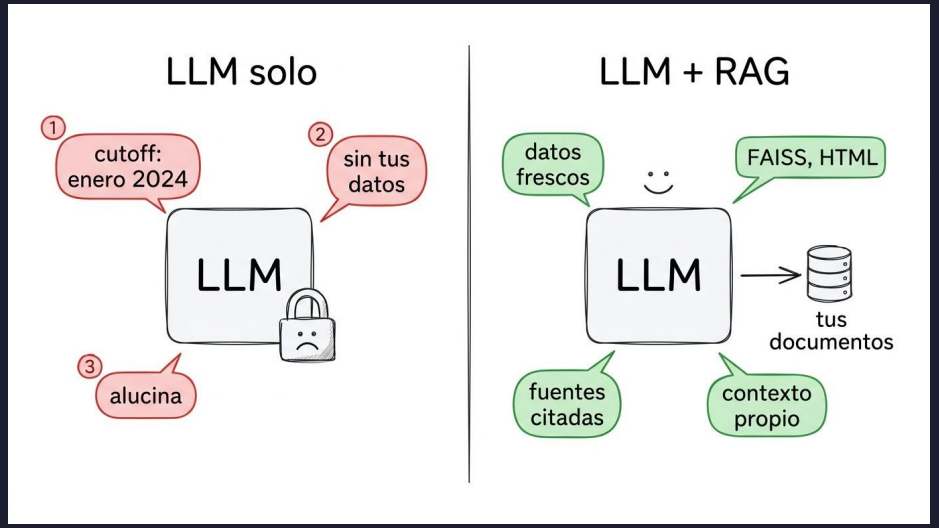
# AI ENGINEERING

## RAG


DEFINICIÓN
MODELO
ADAPTACIÓN
EVALUACIÓN
LLMOPS
PRODUCCIÓN
CASO DE USO
DEFINIR COSTE Y ALCANCE
RAI & ETHICS
MODELO EXISTENTE
PRE-ENTRENAR
PROMPT ENGINEERING
RAG, REACT,...
FINE-TUNING
CUSTOM
BENCHMARKS
OPTIMIZACIÓN
DEPLOY DEL MODELO
API
CREAR LLM-POWERED APPS
AGENTS
OBSERVABILIDAD
TRAZABILIDAD

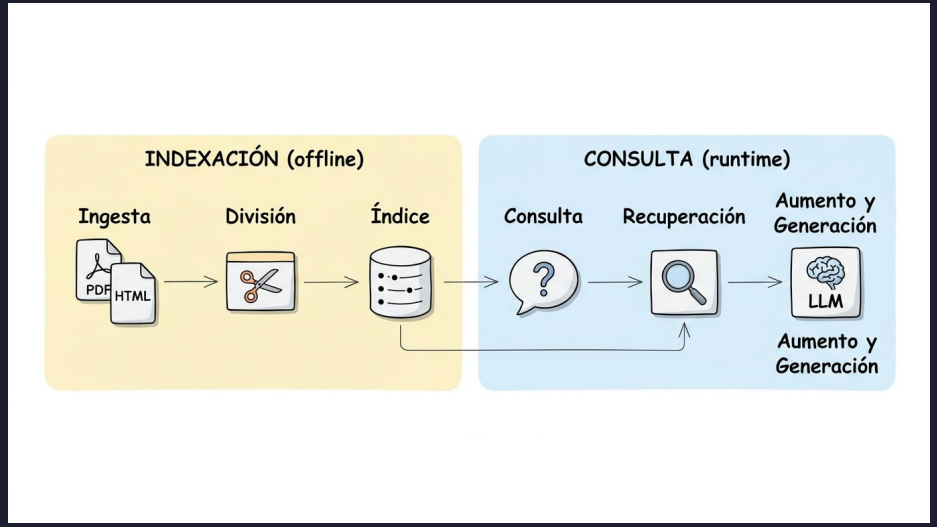
# ¿Por qué RAG?

- El LLM solo : cutoff, alucinaciones, no conoce tus datos
- RAG : el LLM consulta tus documentos en runtime
- Datos frescos sin reentrenar el modelo
- Respuestas con fuentes citadas · trazables
- El patrón productivo más común en 2026



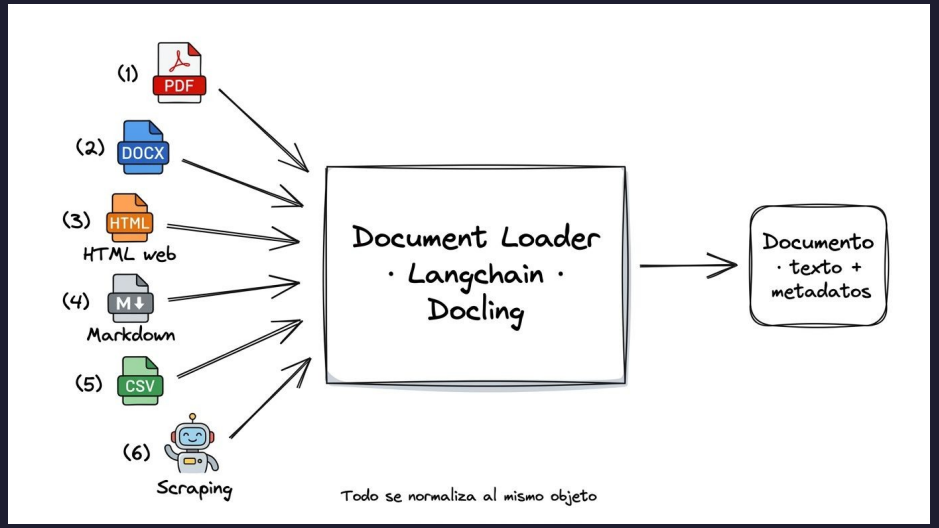
# Flujo RAG completo

- Indexación (offline) : Ingest · Chunk · Index
- Consulta (runtime) : Query · Retrieve · Augment · Generate
- El index se prepara una vez, se consulta millones
- Cada etapa es un sitio donde puedes mejorar (o estropear)



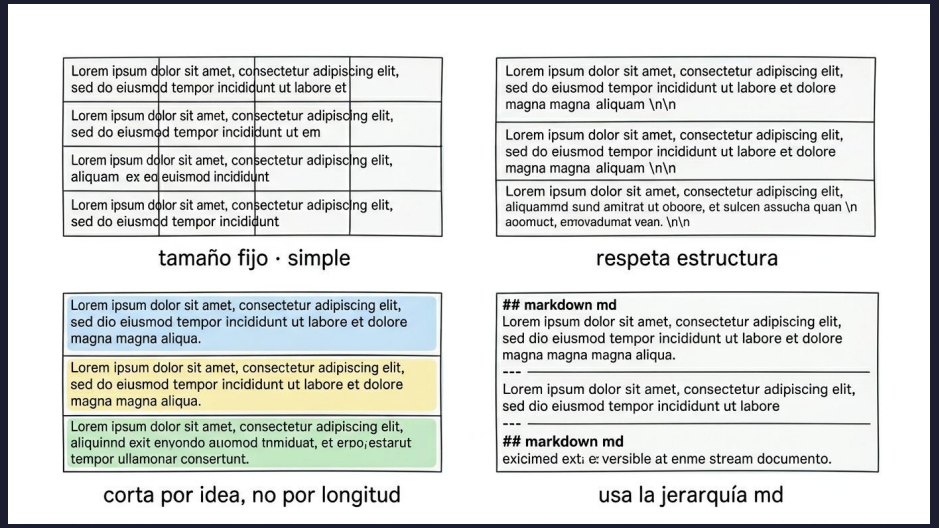
# Document loading

- Formatos : PDF · DOCX · HTML · Markdown · CSV · web scraping
- LangChain DocumentLoader : la abstracción clásica
- Docling (IBM, 2024) : tablas, layouts complejos, OCR
- Todo se normaliza a un objeto Document : texto + metadata
- Labs 01 (loading y chunking) y 02 (Docling)



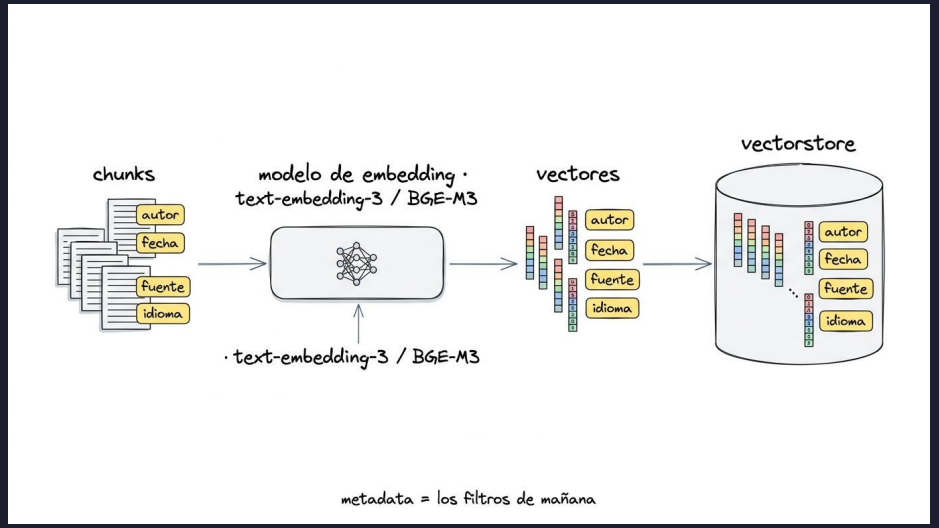
# Chunking · estrategias

- Fixed-size : N caracteres · simple, rompe ideas
- Recursive : respeta saltos de párrafo (default LangChain)
- Semantic : corta donde cambia el significado
- Markdown-aware : usa la jerarquía ## y --- del documento
- El tamaño de chunk afecta retrieval más que el modelo



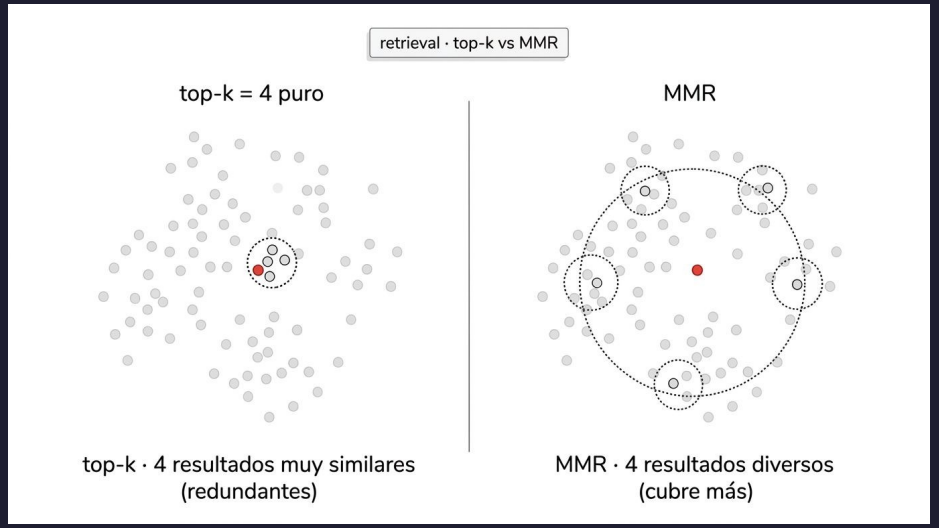
# Embedding e indexación

- Embedder : OpenAI text-embedding-3 · BGE-M3 · Cohere
- Vectorstore : FAISS · Chroma · pgvector · Pinecone (módulo anterior)
- Metadata : autor · fecha · fuente · idioma · sección
- La metadata son los filtros de mañana · guárdala desde el día 1



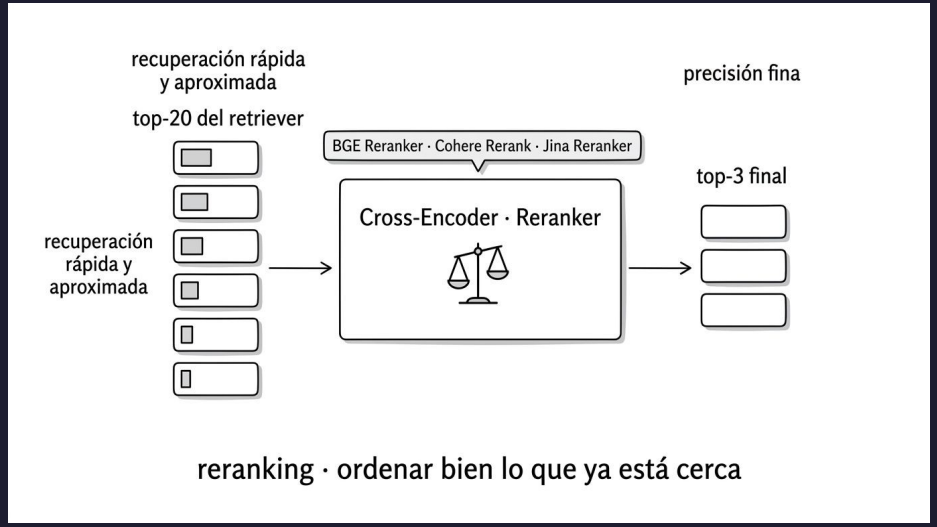
# Retrieval · top-k y MMR

- top-k puro : los k más cercanos · puede ser redundante
- MMR (Maximal Marginal Relevance) : cerca del query + diverso entre sí
- Filtros por metadata : 'solo docs de 2024 sobre fiscalidad'
- k típico : 4 a 10 · más k = más contexto = más coste y ruido



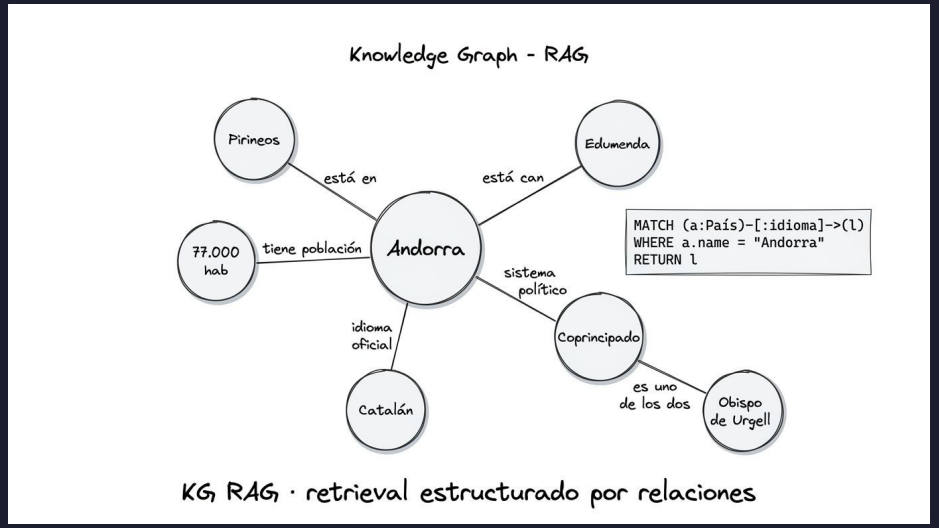
# Reranking

- Bi-encoder (retriever) : rápido pero aproximado · top-20
- Cross-encoder (reranker) : lento pero preciso · top-3
- Combinación : retrieval amplio + rerank fino
- Modelos : Cohere rerank-v3.5 · BGE Reranker v2 · Jina Reranker v2
- Lab 03 : con y sin reranker · mide la mejora, no la supongas



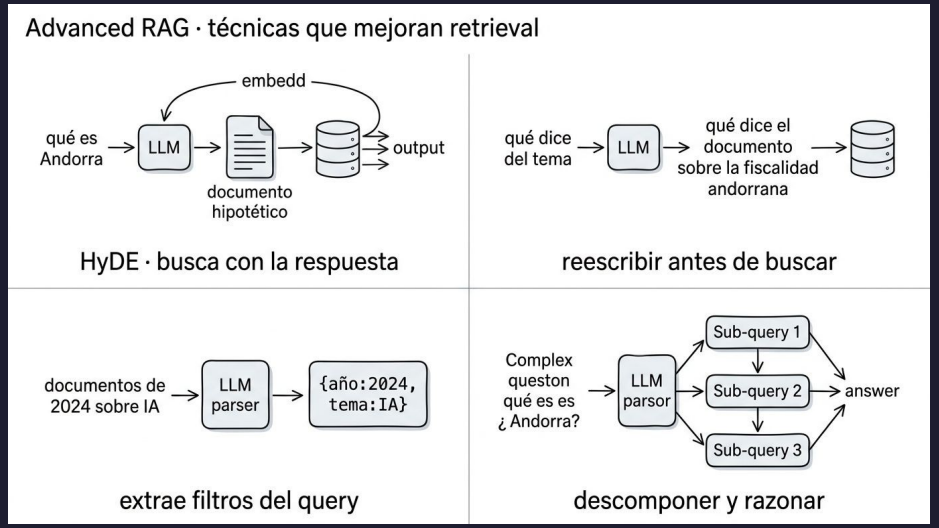
# Knowledge Graph RAG

- Grafos : entidades + relaciones · estructurado
- Cuándo usar : datos con relaciones complejas (legal, médico)
- Stack típico : Neo4j + LLM extrae entidades · Cypher para query
- Híbrido vector + KG : lo mejor de ambos mundos
- Labs 05 (KG desde cero) y 06 (Neo4j + Cypher)



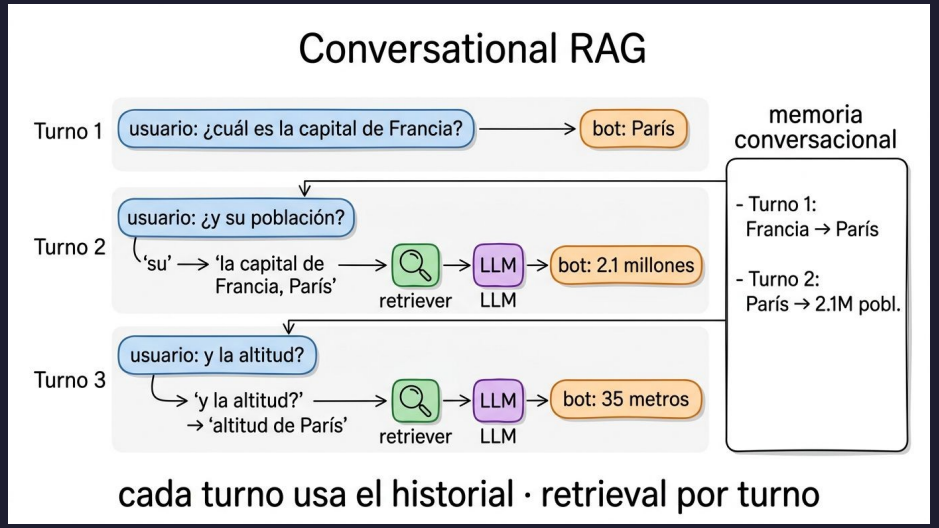
# Advanced RAG

- HyDE : el LLM genera la respuesta hipotética, busca con eso
- Query rewriting : reformular antes de buscar
- Self-query : el LLM extrae filtros de metadata del query
- Multi-hop : descomponer pregunta compleja en sub-queries
- Cuándo : cuando retrieval básico no da



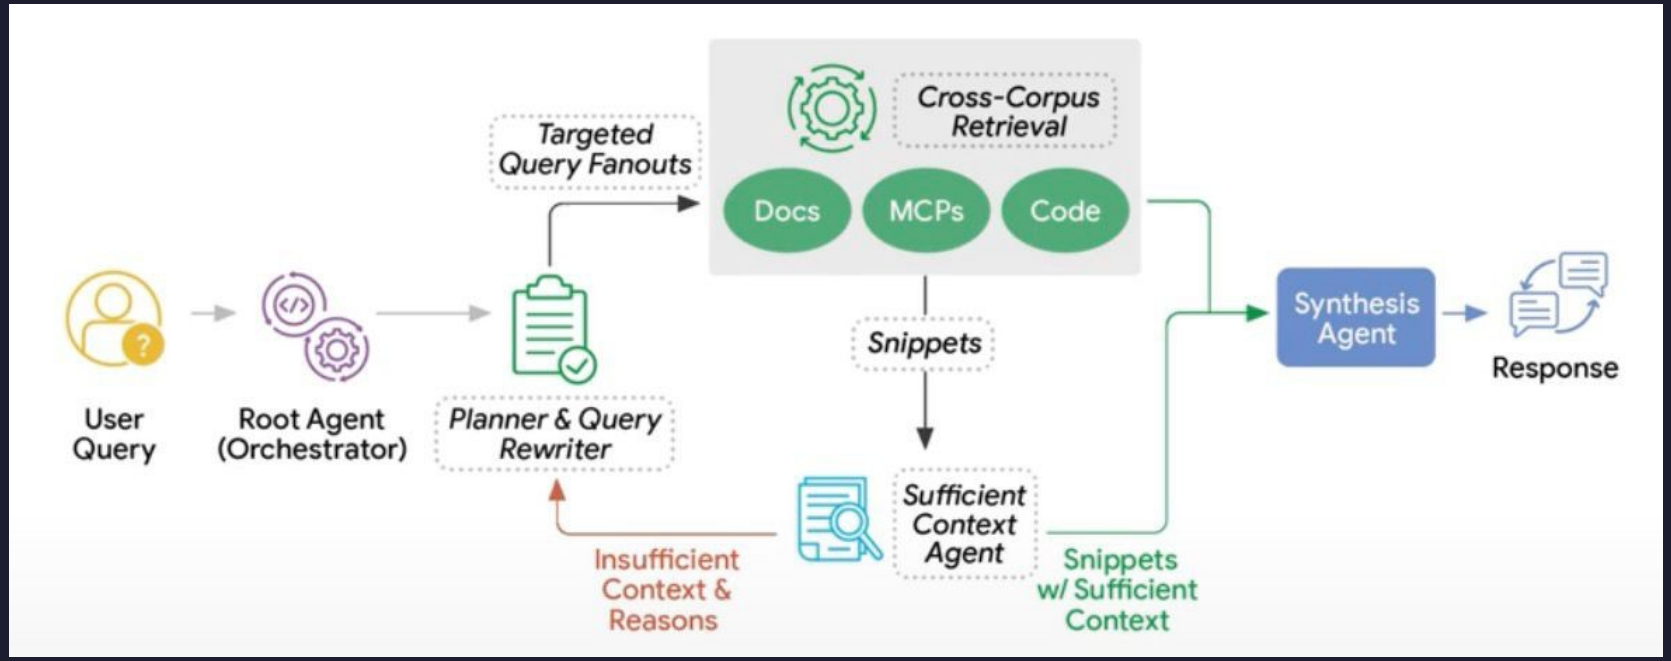
# RAG conversacional

- Cada turno reformula el query con el historial
- '¿y su población?' → 'la población de París'
- Memoria : los N turnos previos · o un resumen
- Retrieval por turno · cada pregunta busca de nuevo
- Hoy : LangGraph con memoria (ConversationalRetrievalChain es legacy)



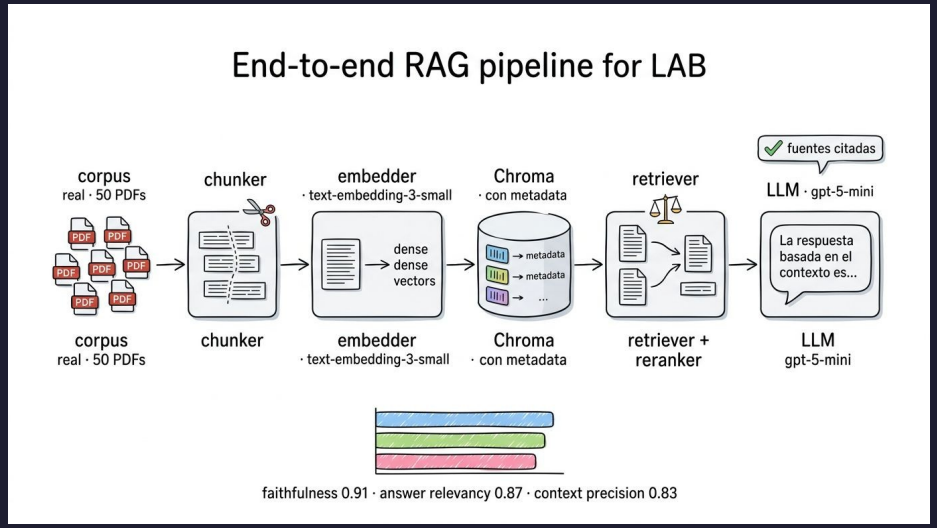
# RAG agéntico · lab 09

keep coding



# LAB · RAG end-to-end

- Corpus : 3 papers de arxiv · el pipeline es el mismo a escala
- Chroma persistente + filtros de metadata + Cohere rerank-v3.5
- Hybrid search : BM25 + dense + RRF
- Generación con gpt-5-mini · respuestas con fuentes citadas
- Notebook : 04-RAG end-to-end.ipynb

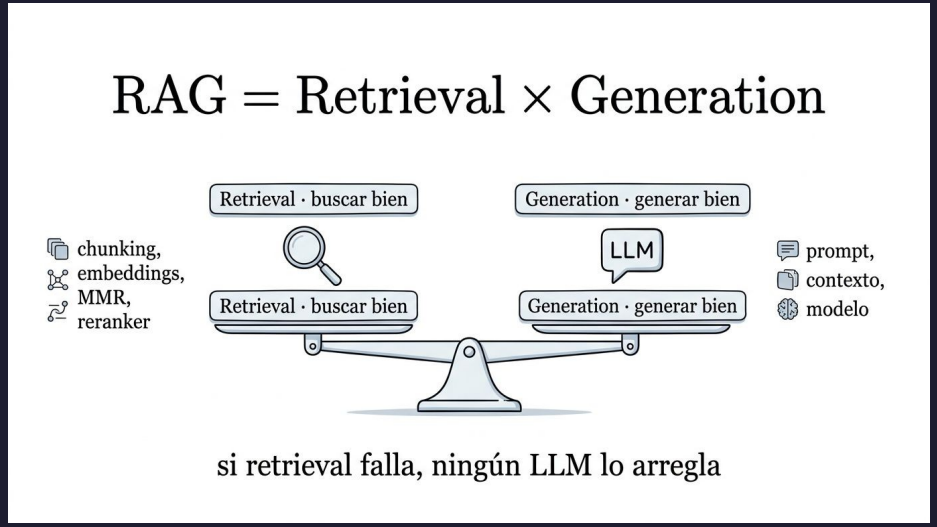


# ¿RAG, CAG, FT o long context?

- RAG : corpus grande o cambiante · necesitas citar fuentes
- CAG : corpus estable que cabe en contexto · prompt caching del proveedor
- Fine-tuning : formato, estilo o tarea fija · no hechos que cambian
- Long context : pocos documentos y pocas queries · cero infra
- Labs 07 (RAG vs CAG) y 08 (matriz de decisión y costes)

# Recap

- RAG = Retrieval × Generation · si uno falla, el otro no rescata
- Empieza simple : recursive chunking + Chroma + top-k = ya funciona
- Mejora donde duele : reranker · advanced queries · KG si las relaciones importan
- Siguiente módulo : cómo evaluar un RAG




keep coding