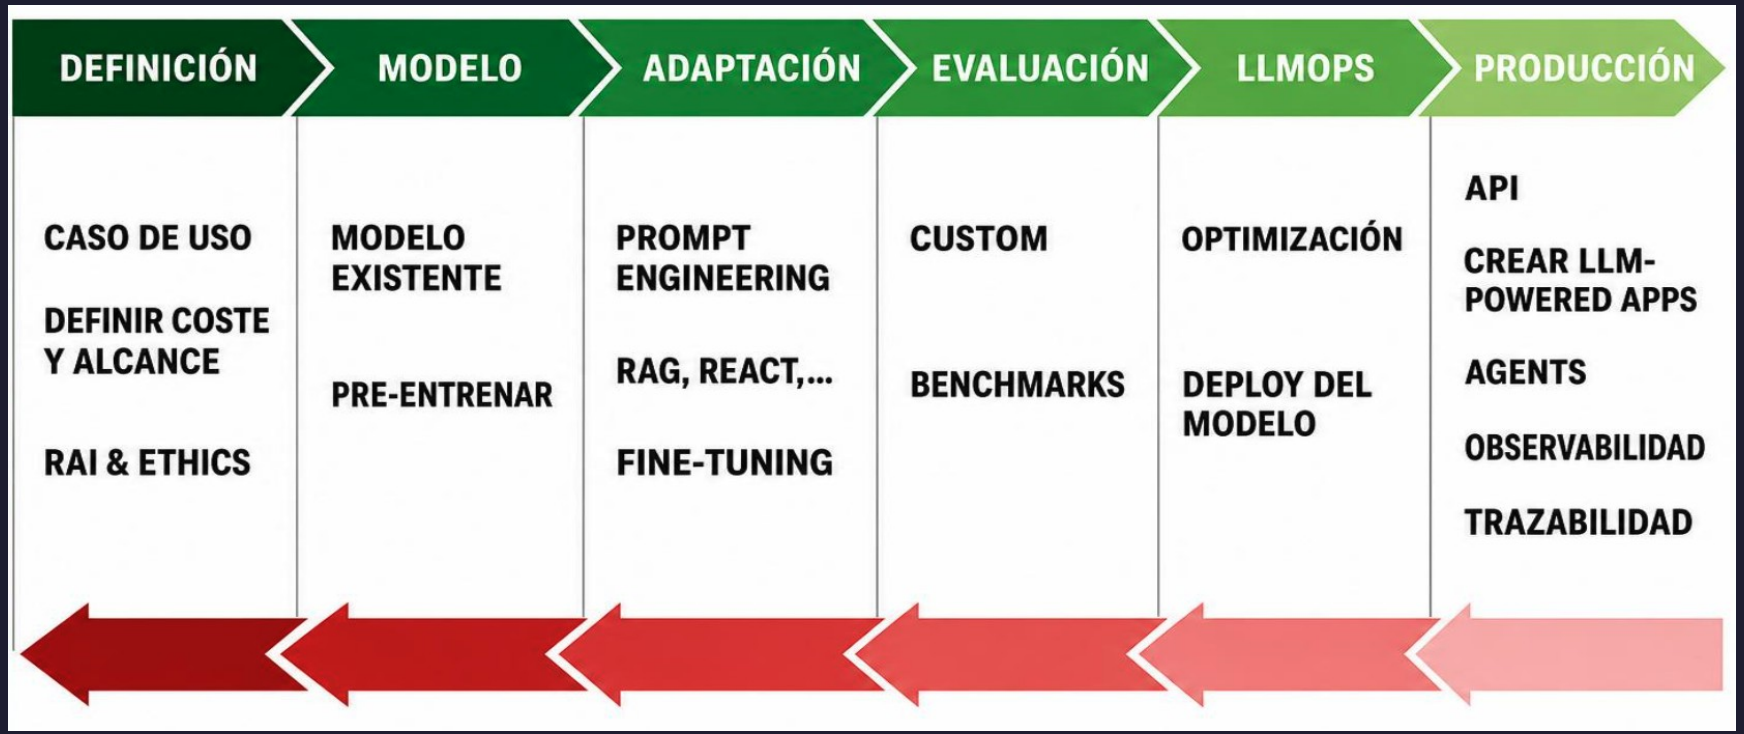
keep coding

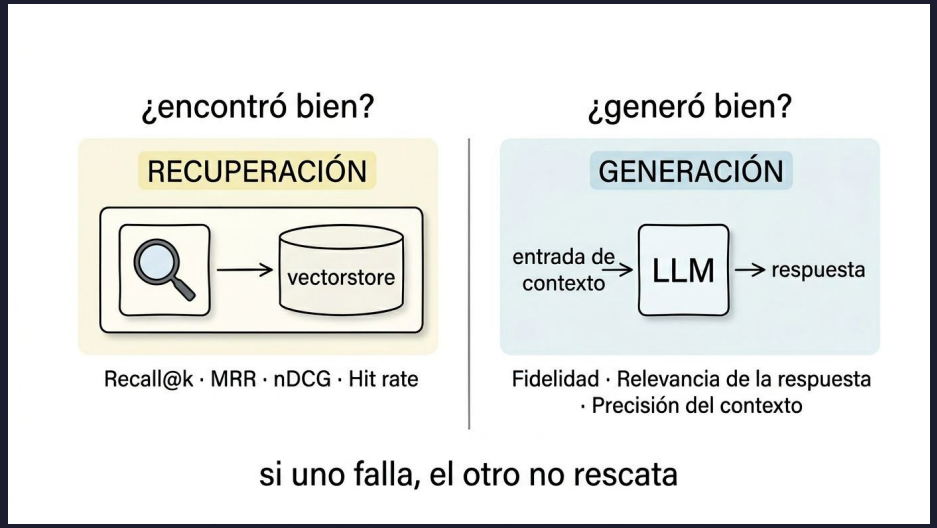
# AI ENGINEERING

## Evaluación de RAG


DEFINICIÓN
MODELO
ADAPTACIÓN
EVALUACIÓN
LLMOPS
PRODUCCIÓN
CASO DE USO
DEFINIR COSTE Y ALCANCE
RAI & ETHICS
MODELO EXISTENTE
PRE-ENTRENAR
PROMPT ENGINEERING
RAG, REACT,...
FINE-TUNING
CUSTOM
BENCHMARKS
OPTIMIZACIÓN
DEPLOY DEL MODELO
API
CREAR LLM-POWERED APPS
AGENTS
OBSERVABILIDAD
TRAZABILIDAD

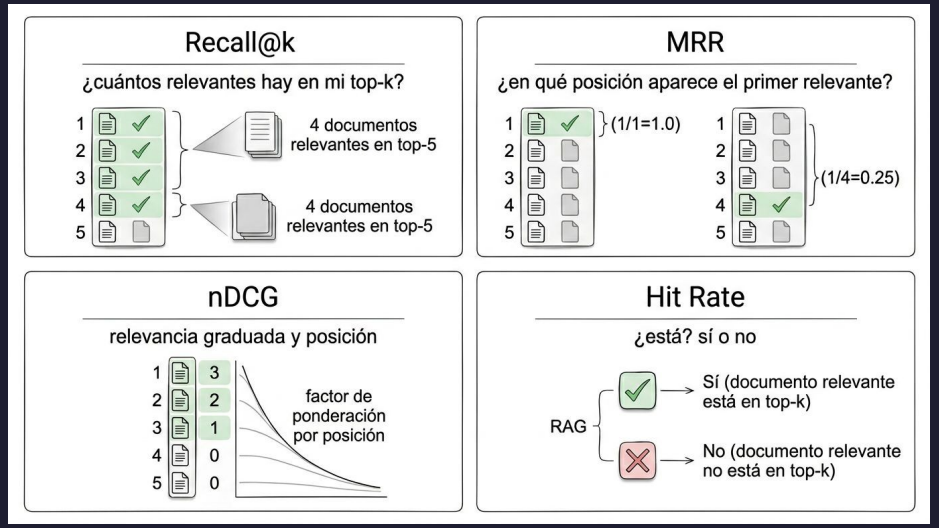
# ¿Qué se evalúa en RAG?

- RAG = Retrieval × Generation · medir cada uno por separado
- Si retrieval falla, ningún LLM lo arregla
- Si retrieval es perfecto, un mal prompt arruina la respuesta
- La métrica agregada esconde de cuál de los dos viene el problema



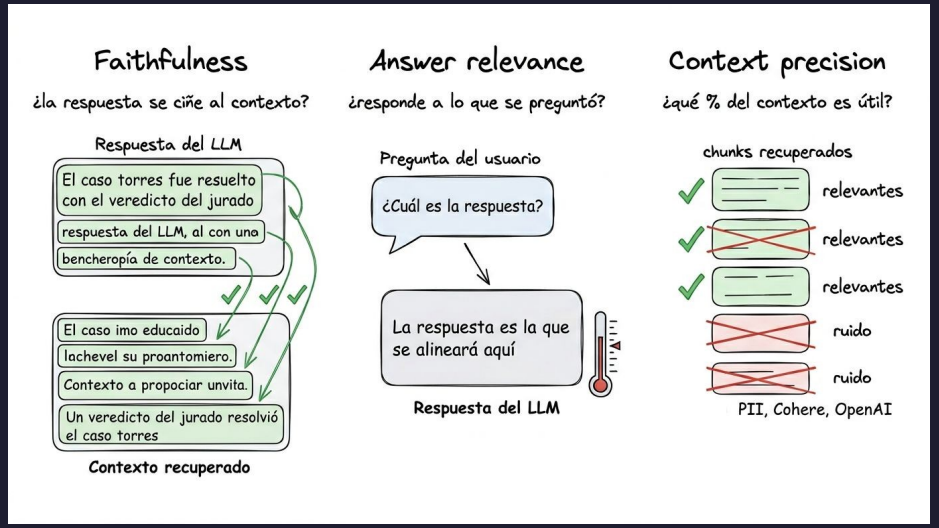
# Retrieval metrics

- Recall@k : ¿cuántos relevantes hay en mi top-k?
- MRR : ¿en qué posición aparece el primer relevante?
- nDCG : combina relevancia graduada y posición
- Hit rate : ¿está el relevante? sí o no
- Necesitan ground truth · golden dataset



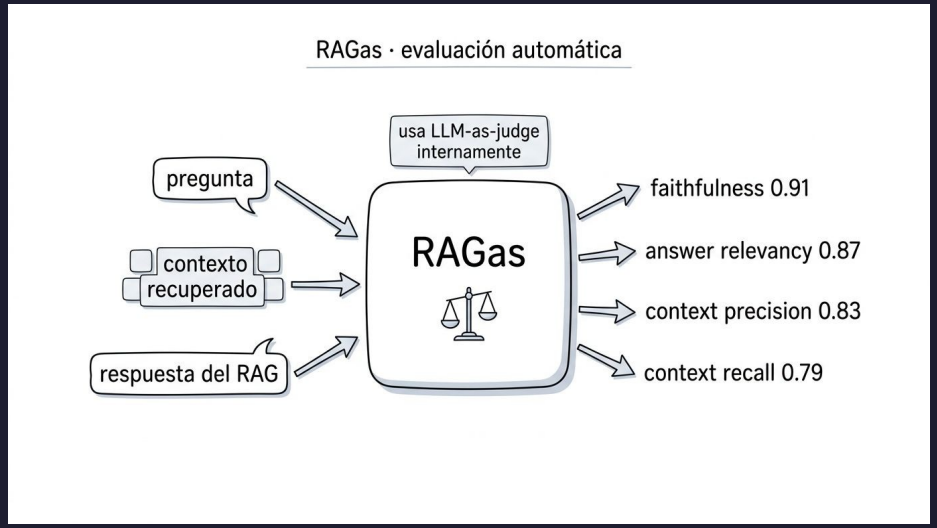
# Métricas de RAGas

- Faithfulness : ¿la respuesta se ciñe al contexto? (no alucina)
- Answer relevancy : ¿responde a lo que se preguntó?
- Context precision : ¿los chunks útiles salen arriba?
- Context recall : ¿el contexto cubre la respuesta de referencia?
- Las 2 primeras miden generación · las 2 últimas, retrieval



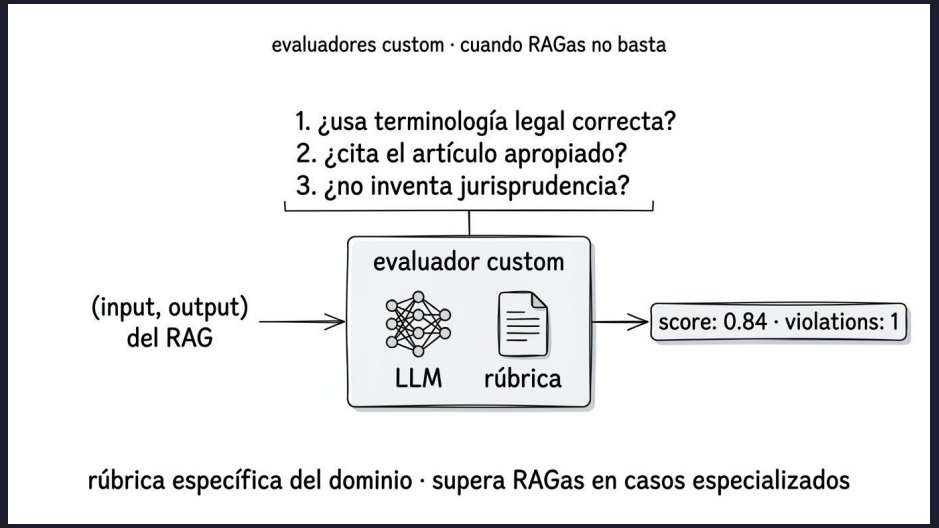
# RAGas · framework

- Open source · 2023 · estándar de facto en eval RAG
- Inputs : pregunta · contexto · respuesta · referencia
- Outputs : un score [0-1] por métrica, sin etiquetar a mano
- Juez : cualquier LLM · en el lab, gpt-4.1-mini
- Notebook : 01-Rag Evaluation & RAGas.ipynb



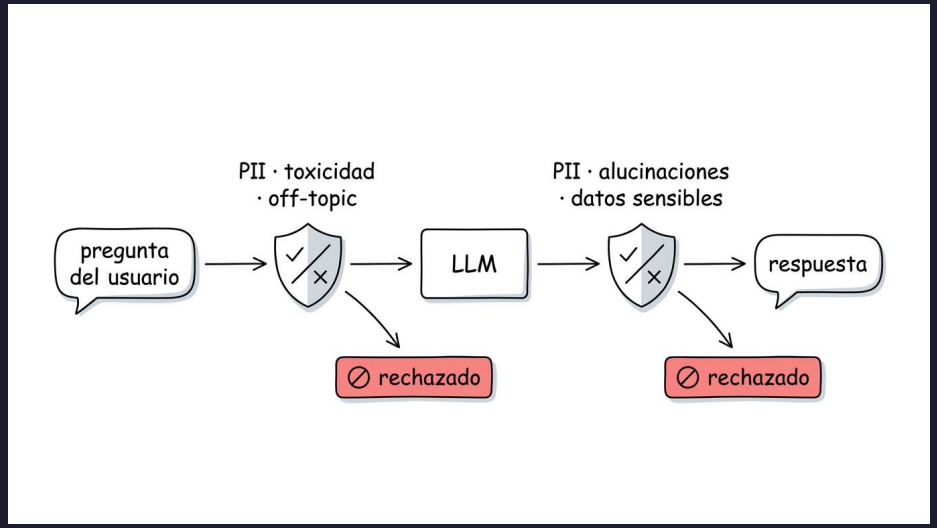
# Custom RAG Evaluation

- Cuándo : tu dominio tiene reglas que RAGas no captura
- Ejemplo legal : cita el artículo · terminología correcta
- Ejemplo médico : no inventa diagnósticos · cita evidencia
- Patrón : LLM + rúbrica del dominio + structured output
- Salida : score 0-1 + lista de violaciones



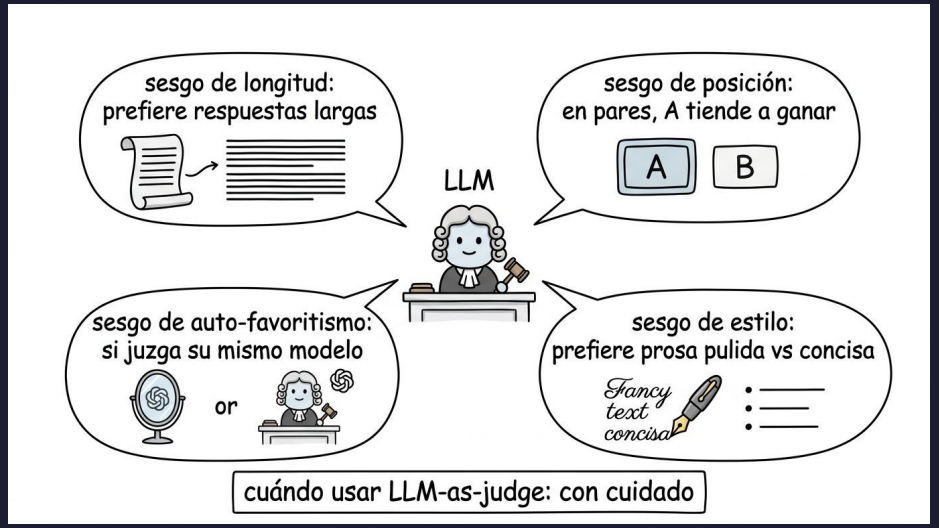
# Guardrails

- Filtros antes y después del LLM
- Input : PII · toxicidad · prompt injection · off-topic
- Output : alucinaciones · datos sensibles · content policy
- Stack : LLM-as-judge · Llama Guard 4 · Guardrails AI · NeMo
- Notebook : 02-Guardrails.ipynb



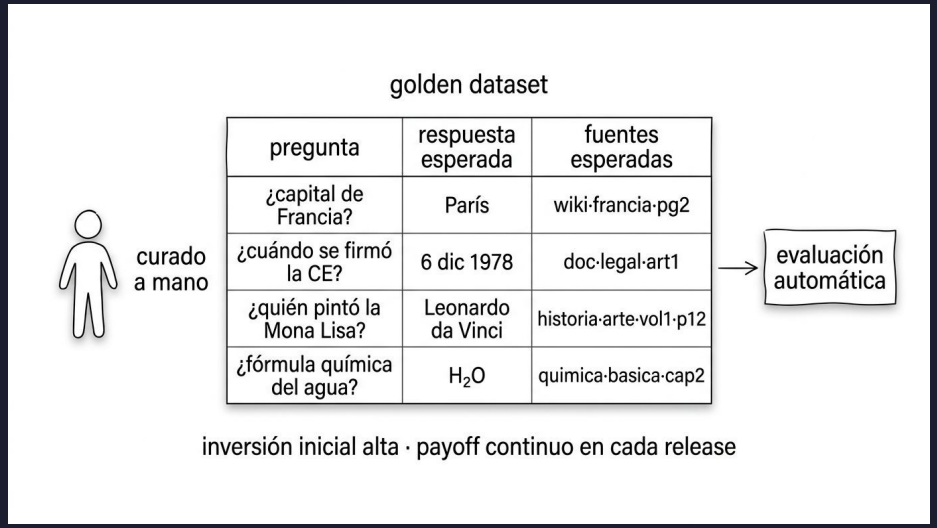
# LLM-as-judge · cuándo

- Funciona bien : criterio claro (relevancia, factualidad)
- Falla : juicios estéticos · dominios muy especializados
- Sesgos : longitud · posición · auto-favoritismo · estilo
- Mitiga : comparar en pares · varios jueces · calibrar con humanos
- Valida el juez antes de confiar en él



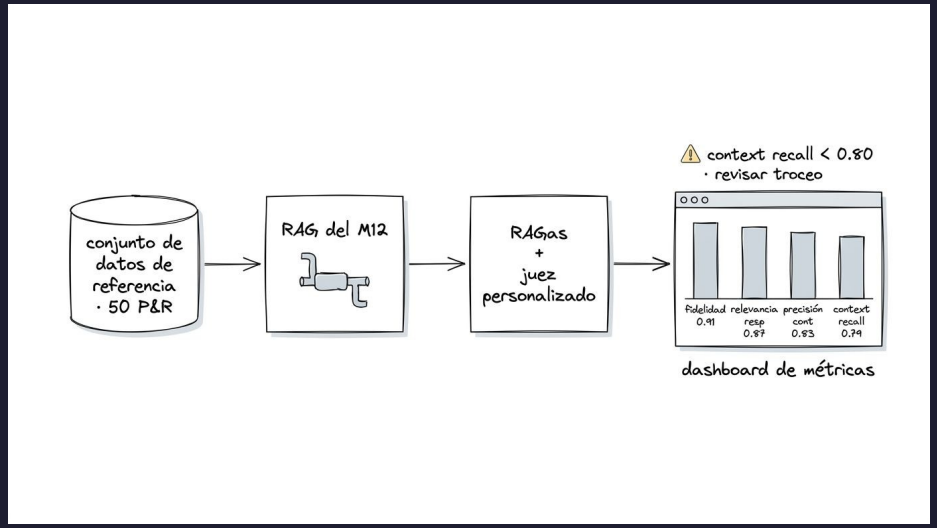
# Golden dataset

- Conjunto curado de Q&A de referencia · 50 a 500 ejemplos
- Necesario para Recall@k · MRR · nDCG · regression tests
- Costoso de crear · payoff continuo en cada release
- Ideal : preguntas que vienen de usuarios reales
- Versiona el dataset · él también evoluciona



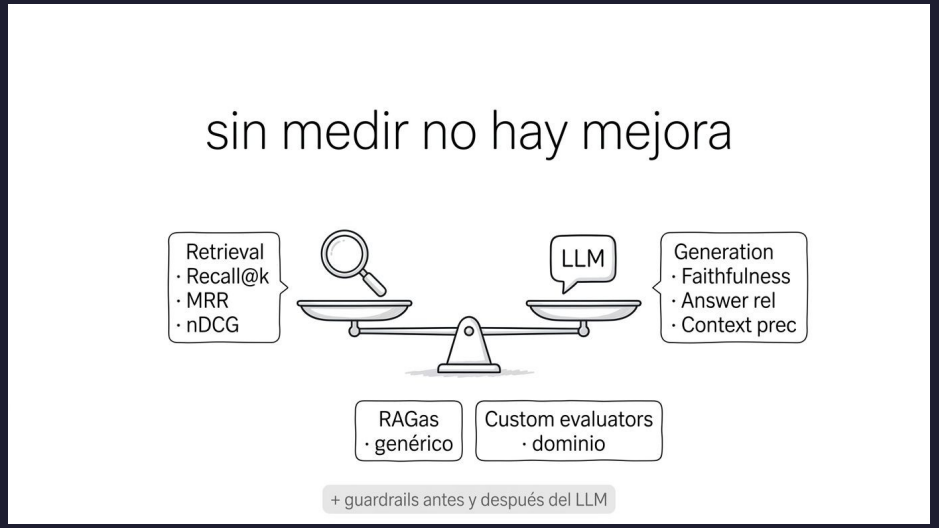
# LAB · evaluar un RAG

- Mini-RAG sobre los 3 papers del módulo de RAG
- Golden dataset sintético · 15 preguntas con structured output
- Las 4 métricas de RAGas · juez gpt-4.1-mini
- Gráfica de resultados · ¿falla retrieval o generación?
- Notebook : 01-Rag Evaluation & RAGas.ipynb



# Recap

- Sin medir no hay mejora · esa es toda la lección
- Mide retrieval y generación por separado
- RAGas para lo genérico · evaluadores custom para tu dominio
- Guardrails antes y después del LLM
- Siguiente : agentes (clase 5) · Langfuse en continuo (clase 6)




keep coding