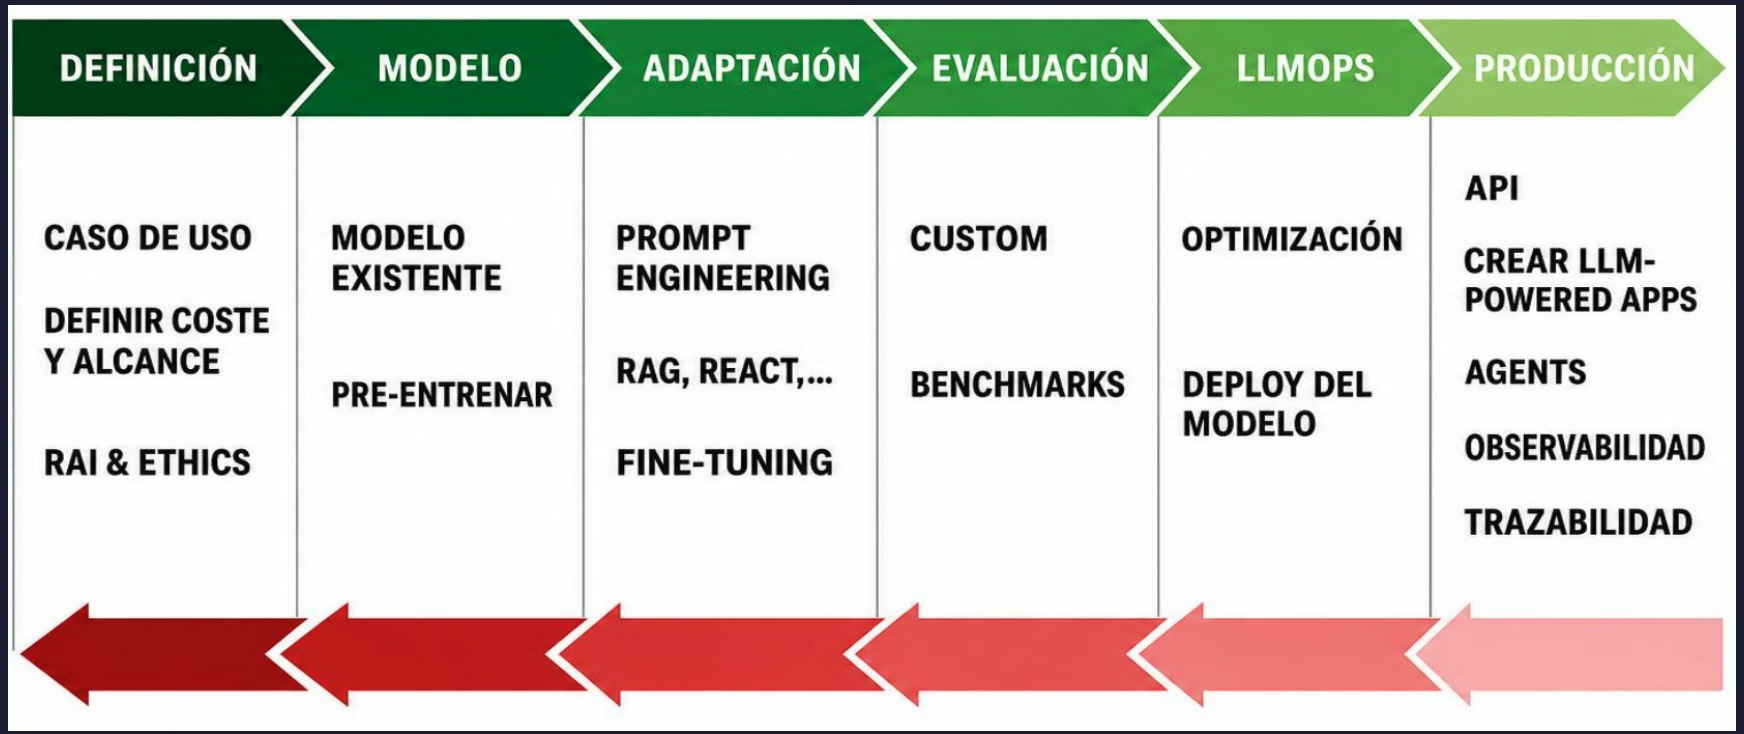
keep coding

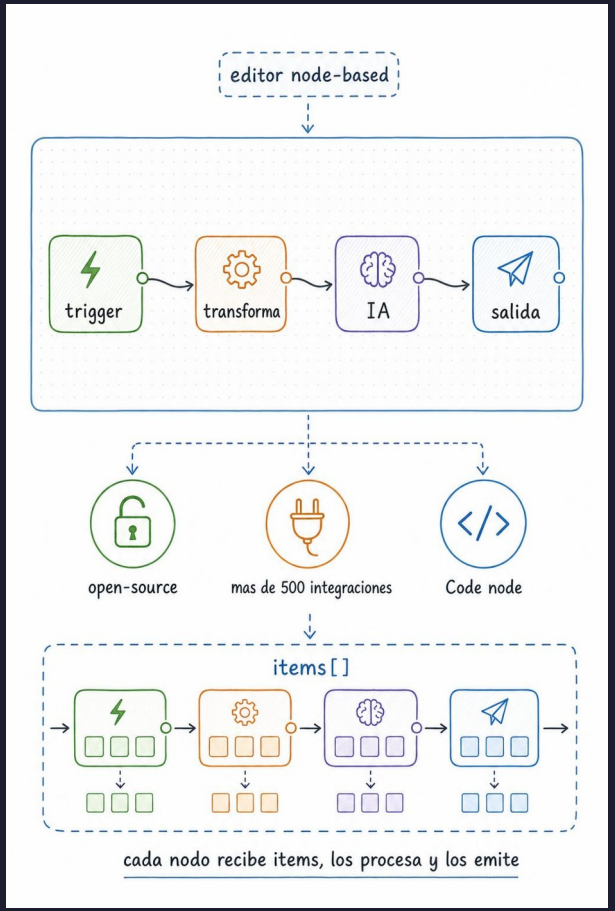
AI ENGINEERING

n8n


DEFINICIÓN
MODELO
ADAPTACIÓN
EVALUACIÓN
LLMOPS
PRODUCCIÓN
CASO DE USO
DEFINIR COSTE Y ALCANCE
RAI & ETHICS
MODELO EXISTENTE
PRE-ENTRENAR
PROMPT ENGINEERING
RAG, REACT,...
FINE-TUNING
CUSTOM
BENCHMARKS
OPTIMIZACIÓN
DEPLOY DEL MODELO
API
CREAR LLM-POWERED APPS
AGENTS
OBSERVABILIDAD
TRAZABILIDAD

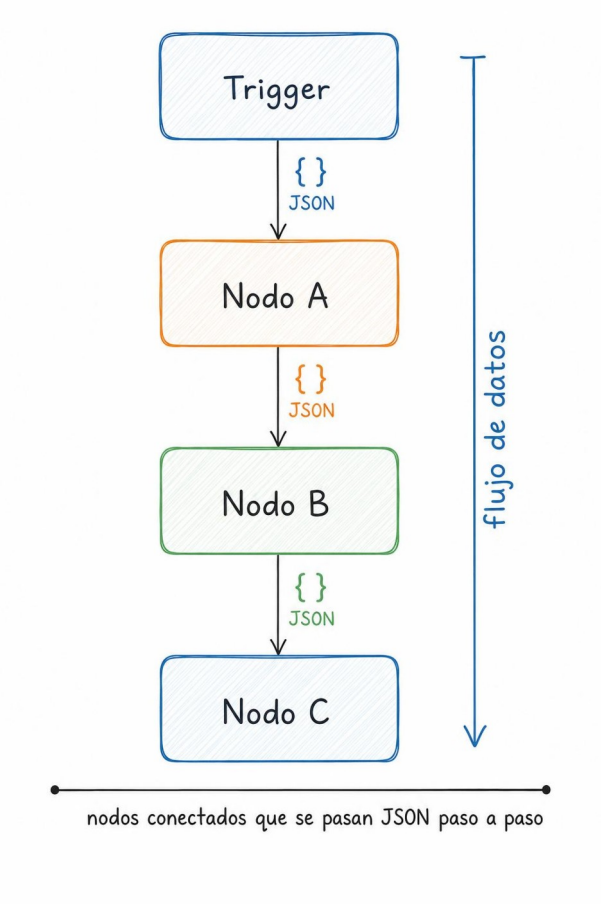
¿Qué es n8n?

- Plataforma open-source de workflow automation · sin escribir código
- Editor visual node-based · drag & drop · más de 500 integraciones
- Cada nodo recibe items[], los procesa y emite items[]
- Code node · JavaScript o Python embebido cuando falta la integración
- Sweet spot · automatización con IA y glue entre SaaS y APIs propias



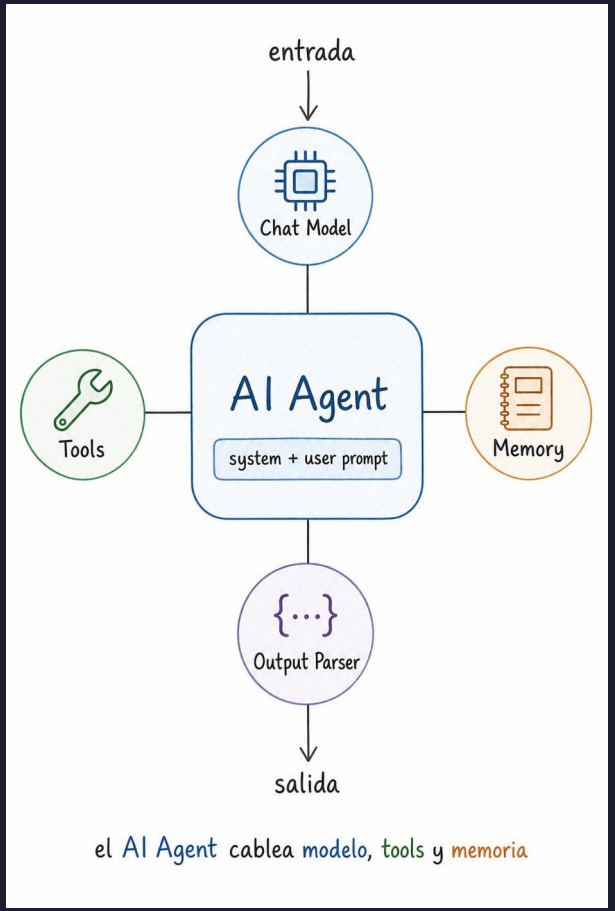
Arquitectura de un workflow

- Workflow · grafo de nodos conectados de un trigger a una salida
- Entre nodos viaja JSON · cada nodo lee la salida del anterior
- Items[] · un nodo procesa una lista, no un solo dato
- Expresiones · {{ $json.campo }} referencia datos de nodos previos
- Lo que escribirías en código aquí se cablea visualmente



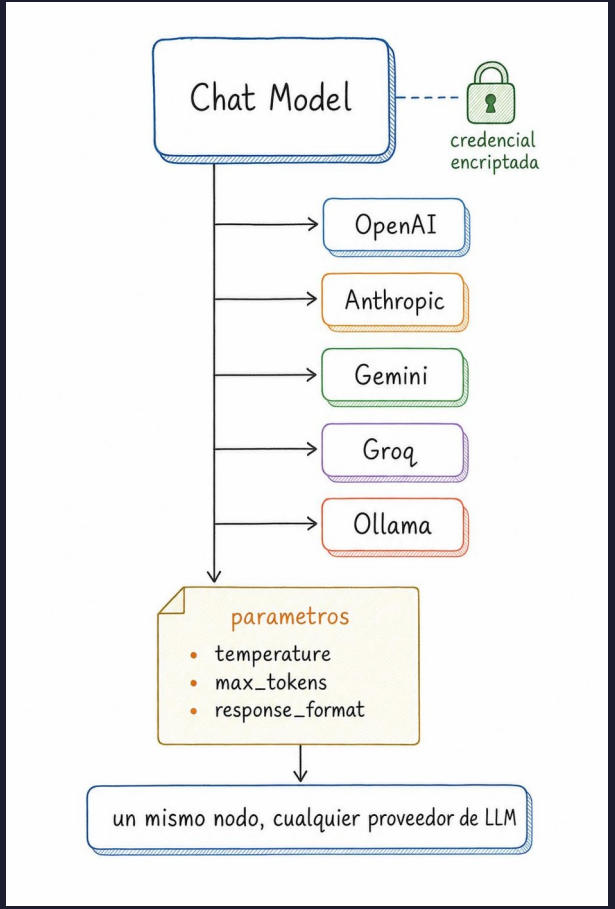
El nodo AI Agent

- AI Agent node · agente Langchain-like dentro del workflow
- Configurable con system + user prompt · sin escribir código
- Sub-nodos conectados · Chat Model, Tools, Memory, Output Parser
- Tipos · Tools Agent (function calling), ReAct, Conversational
- El mismo agente que harías en código, cableado con nodos



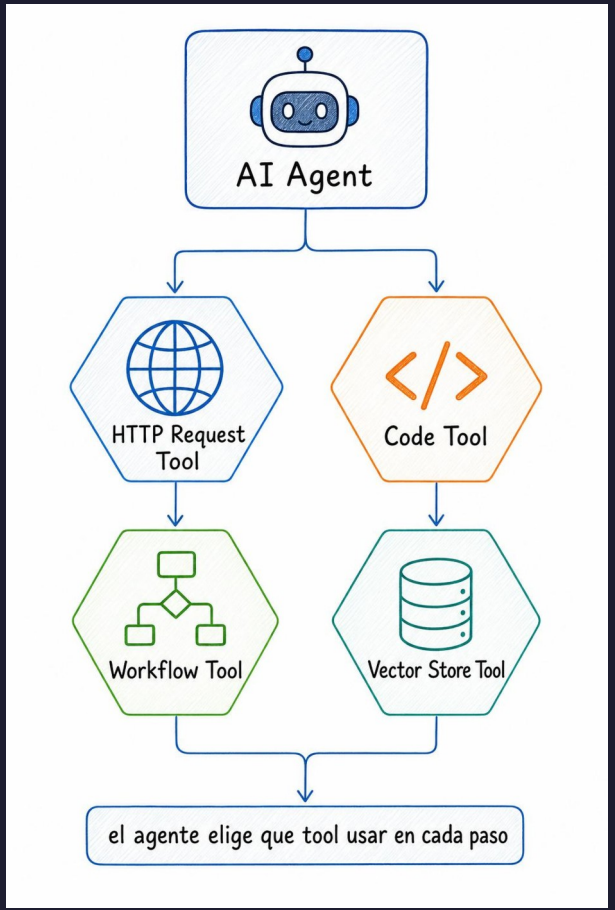
Chat Model · el LLM del agente

- Chat Model node · sub-nodo que da el LLM al AI Agent
- Proveedores · OpenAI, Anthropic, Gemini, Groq, Ollama, Azure
- Credenciales encriptadas en BD · una vez, reutilizables en todo
- Parámetros expuestos · temperature, max_tokens, response_format
- Cambiar de modelo es cambiar un sub-nodo, no reescribir el flow



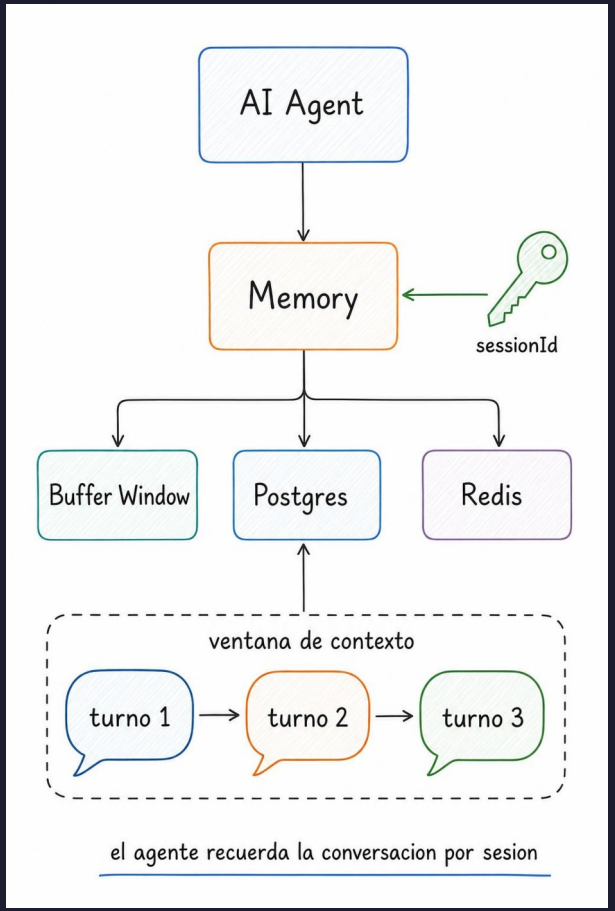
Tools en el AI Agent

- Tools · sub-nodos que el agente puede invocar para actuar
- HTTP Request Tool · llama a una API externa como herramienta
- Code Tool · ejecuta JavaScript o Python a demanda
- Vector Store Tool · expone un retriever como tool · RAG agéntico
- Workflow Tool · invoca otro workflow entero como herramienta



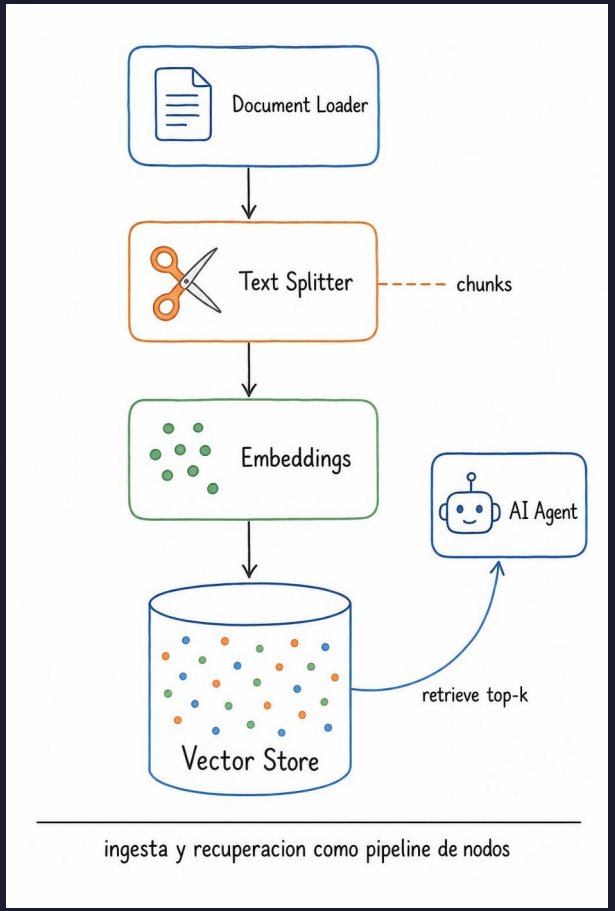
Memory en el AI Agent

- Memory · sub-nodo que da al agente historial de conversación
- Buffer Window · ventana de los últimos N mensajes en RAM
- Postgres y Redis Chat Memory · memoria persistente entre sesiones
- sessionId · separa la conversación de cada usuario
- Sin memoria es un chatbot sin contexto del turno anterior



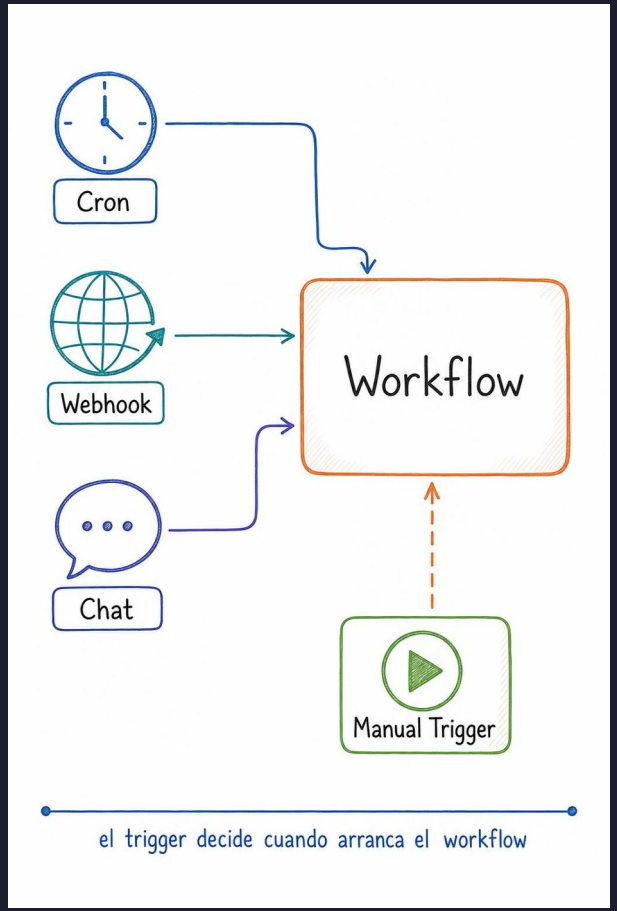
RAG visual

- Document Loader · carga PDF, texto, JSON, CSV desde binario
- Text Splitter · trocea en chunks · chunk_size + overlap
- Embeddings y Vector Store · Pinecone, Qdrant, pgvector, Postgres
- Ingesta · Loader → Splitter → Embeddings → Vector Store (insert)
- Query · Vector Store (retrieve top-k) → AI Agent con contexto



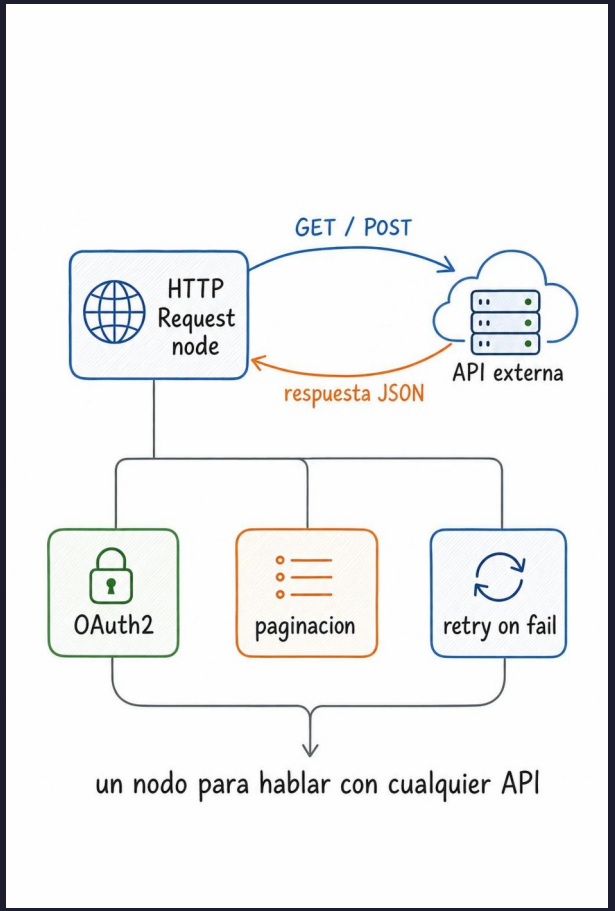
Triggers

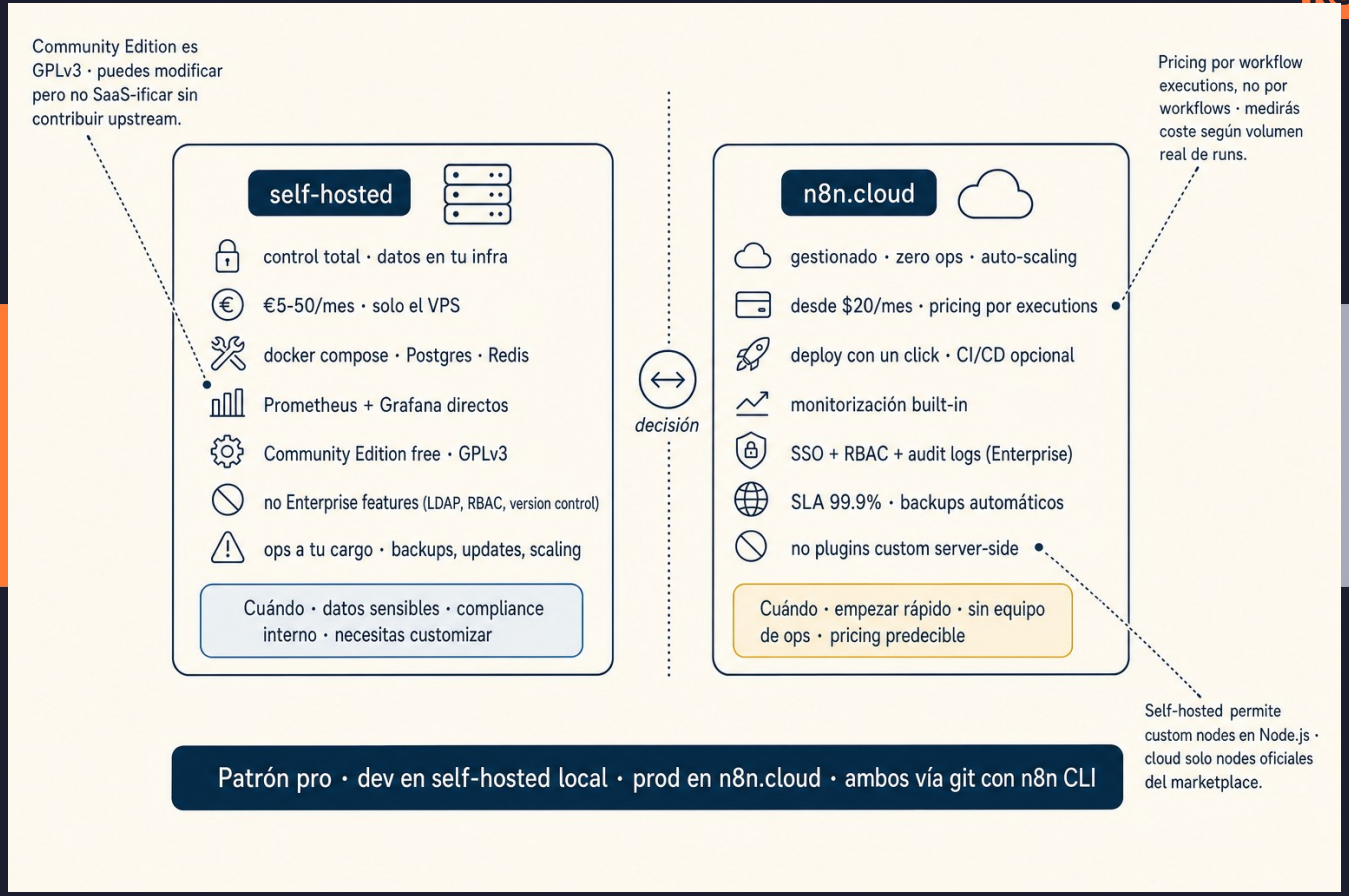
- Trigger · el nodo de entrada que arranca el workflow
- Schedule Trigger · cron estándar · timezone por workflow
- Webhook Trigger · URL pública · GET/POST · binary y form-data
- Chat Trigger · UI de chat embebible · session memory automática
- Manual Trigger · ejecución on-demand · ideal para depurar



Conexión con APIs externas

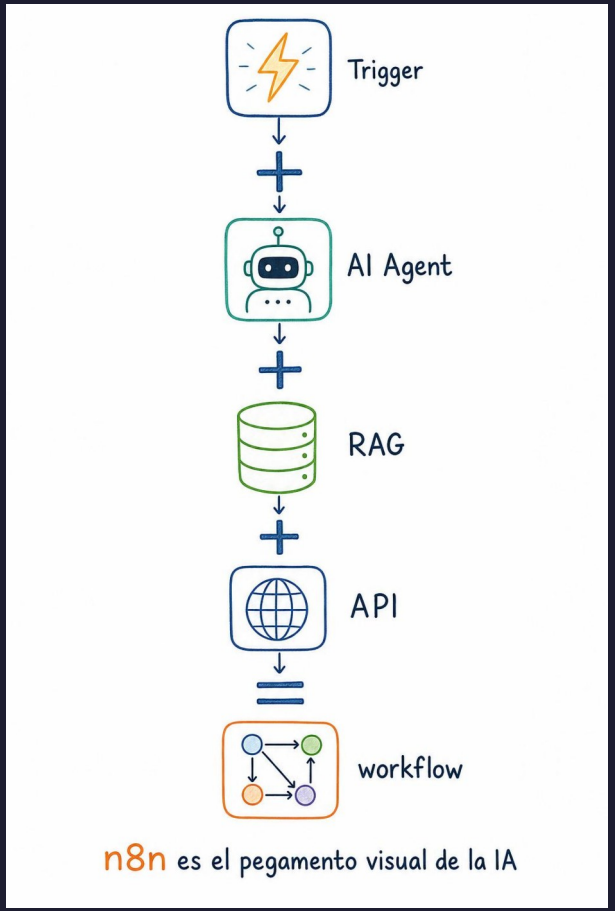
- HTTP Request node · GET/POST/PUT/PATCH/DELETE · headers y body
- Credenciales genéricas · Header Auth, OAuth2, API Key, Bearer
- OAuth2 gestionado por n8n · refresh del token automático
- Paginación nativa y retry on fail · esencial para APIs flaky
- Un solo nodo para hablar con cualquier servicio del mundo




Community Edition es GPLv3 · puedes modificar pero no SaaS-ificar sin contribuir upstream.
self-hosted
control total · datos en tu infra
€5-50/mes · solo el VPS
docker compose · Postgres · Redis
Prometheus + Grafana directos
Community Edition free · GPLv3
no Enterprise features (LDAP, RBAC, version control)
ops a tu cargo · backups, updates, scaling
Cuándo · datos sensibles · compliance interno · necesitas customizar
decisión
n8n.cloud
gestionado · zero ops · auto-scaling
desde $20/mes · pricing por executions
deploy con un click · CI/CD opcional
monitorización built-in
SSO + RBAC + audit logs (Enterprise)
SLA 99.9% · backups automáticos
no plugins custom server-side
Cuándo · empezar rápido · sin equipo de ops · pricing predecible
Pricing por workflow executions, no por workflows · medirás coste según volumen real de runs.
Self-hosted permite custom nodes en Node.js · cloud solo nodes oficiales del marketplace.
Patrón pro · dev en self-hosted local · prod en n8n.cloud · ambos vía git con n8n CLI

Recap

- n8n es el pegamento visual entre triggers, LLMs y APIs
- AI Agent node · agente con tools y memory sin escribir código
- RAG visual end-to-end · ingesta y retrieval como pipelines
- Webhooks + Respond convierten un workflow en endpoint HTTP
- Prototipa rápido lo que en código tardarías mucho más




keep coding