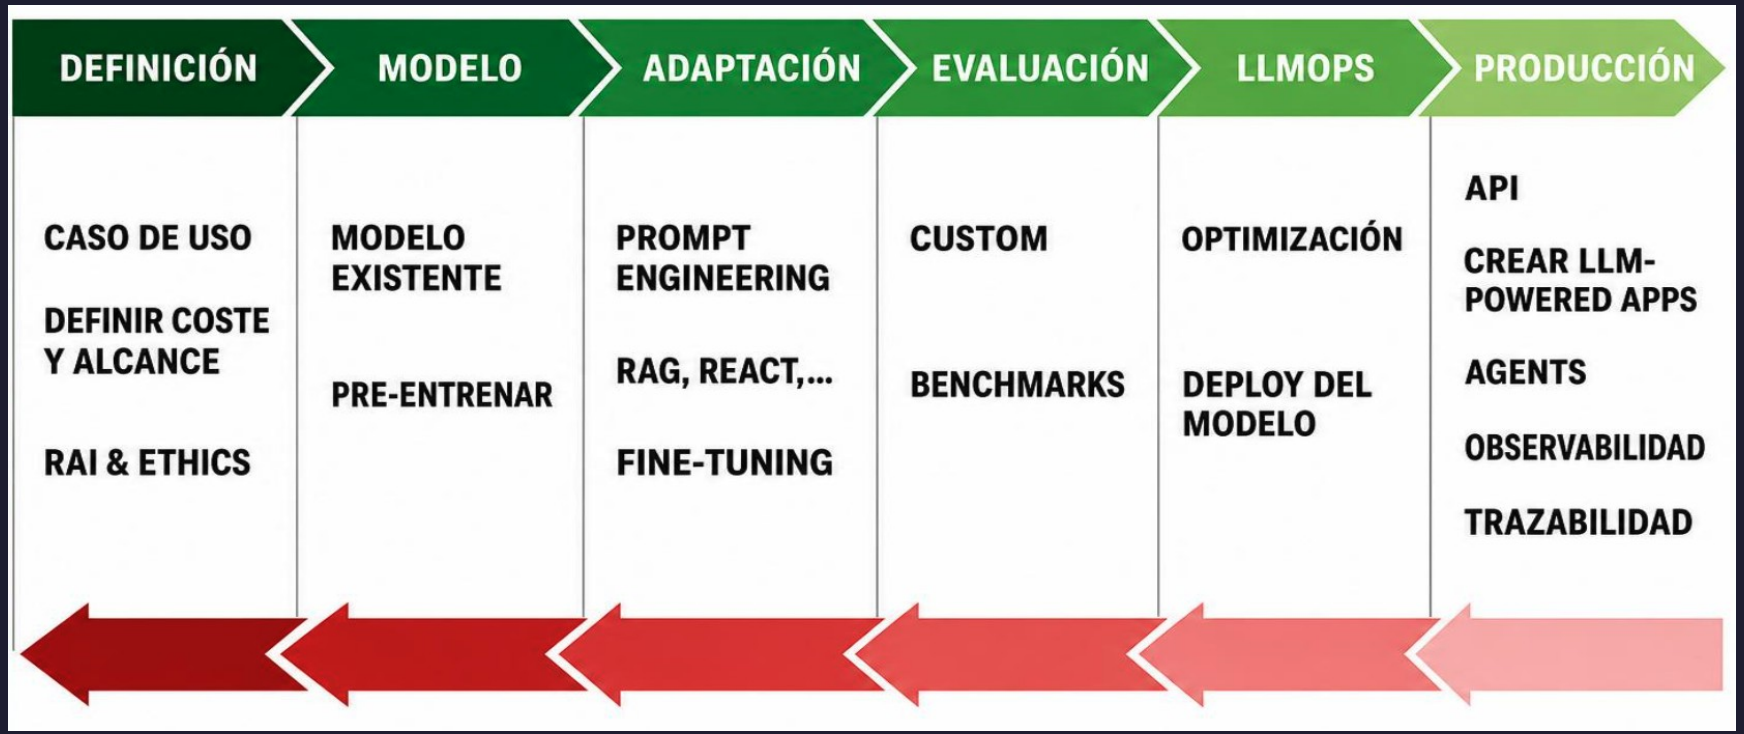
keep coding

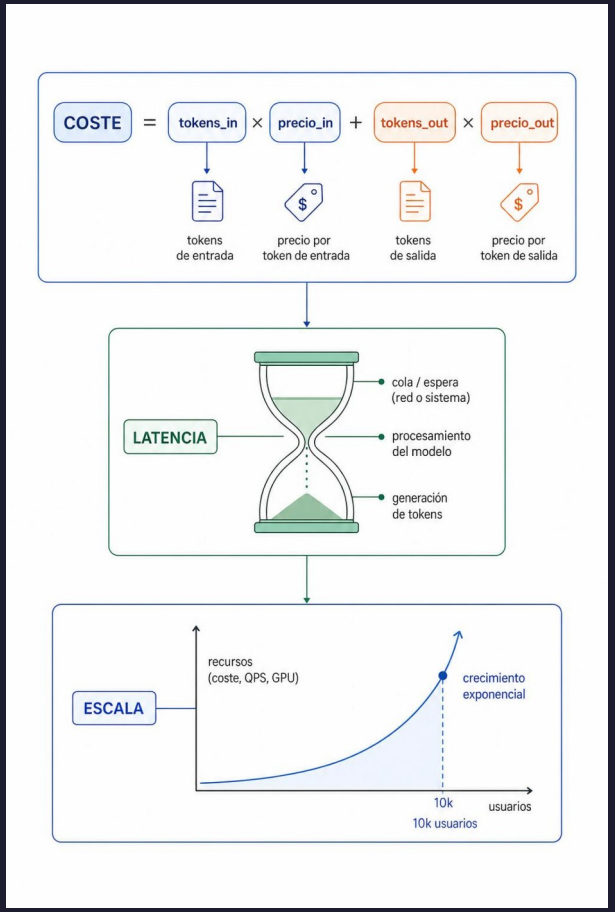
AI ENGINEERING

Coste y latencia


DEFINICIÓN
MODELO
ADAPTACIÓN
EVALUACIÓN
LLMOPS
PRODUCCIÓN
CASO DE USO
DEFINIR COSTE Y ALCANCE
RAI & ETHICS
MODELO EXISTENTE
PRE-ENTRENAR
PROMPT ENGINEERING
RAG, REACT,...
FINE-TUNING
CUSTOM
BENCHMARKS
OPTIMIZACIÓN
DEPLOY DEL MODELO
API
CREAR LLM-POWERED APPS
AGENTS
OBSERVABILIDAD
TRAZABILIDAD

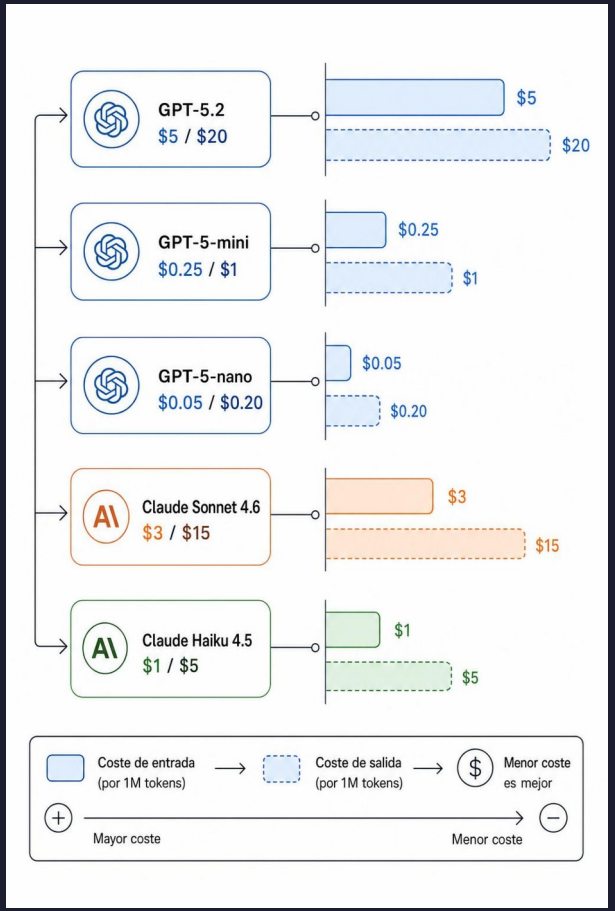
El problema

- Sin optimizar, las LLM apps son caras y lentas
- Coste = tokens_in × precio_in + tokens_out × precio_out
- Latencia = TTFT + tiempo de generación
- Una mala arquitectura escala mal a 10k usuarios
- Mide primero, optimiza después



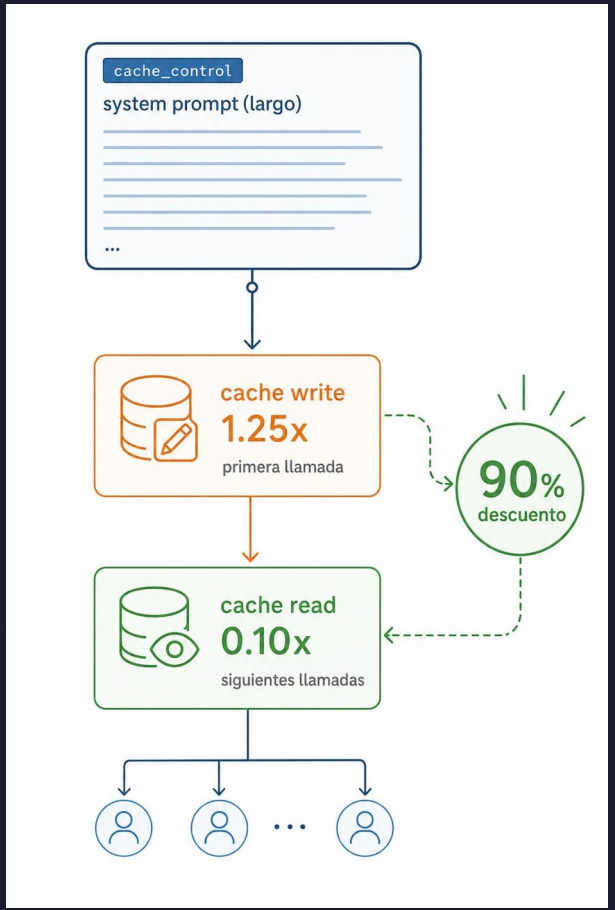
Precios oct 2026 (por 1M tokens)

- GPT-5.2: $1.75 in / $14 out
- GPT-5-mini: $0.25 / $2
- GPT-5-nano: $0.05 / $0.40
- Claude Sonnet 4.6: $3 / $15
- Claude Haiku 4.5: $1 / $5



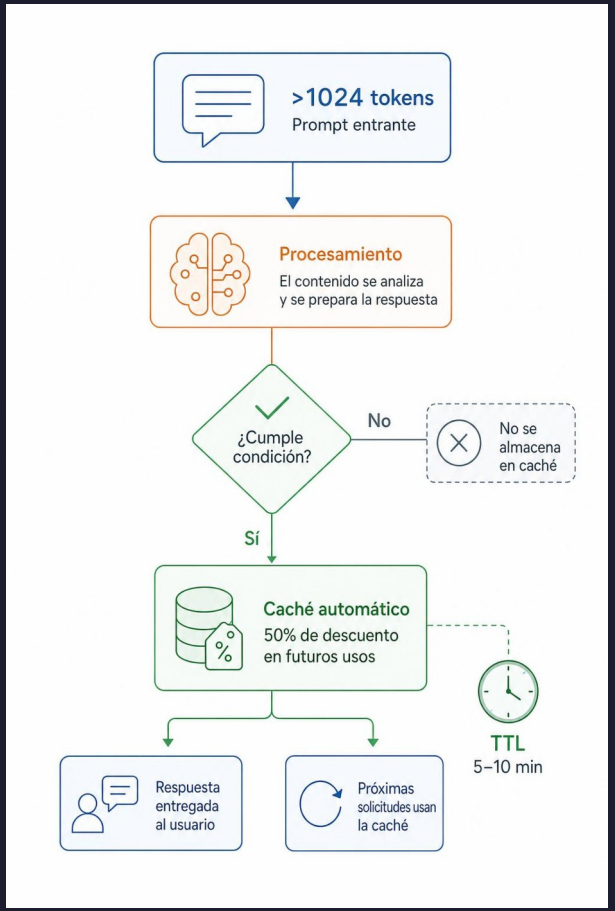
Prompt caching en Anthropic

- Escritura en caché: 1,25× (5 min) o 2× (1 h)
- Lectura de caché: 0,1× (90 % de descuento)
- También baja la latencia
- Cache breakpoints explícitos con cache_control
- Ideal para system prompts largos y contexto RAG



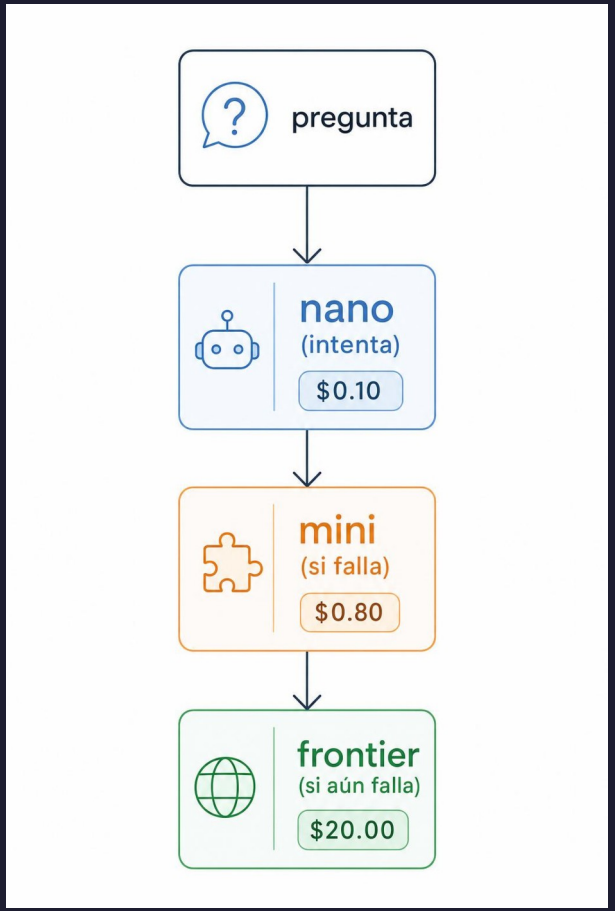
Prompt caching en OpenAI

- Automático a partir de 1.024 tokens de prefijo
- Hasta 90 % de descuento en input cacheado (GPT-5)
- Sin cambios de código; prompt_cache_key ayuda
- La caché se calienta con el uso repetido
- Vive unos minutos en uso normal



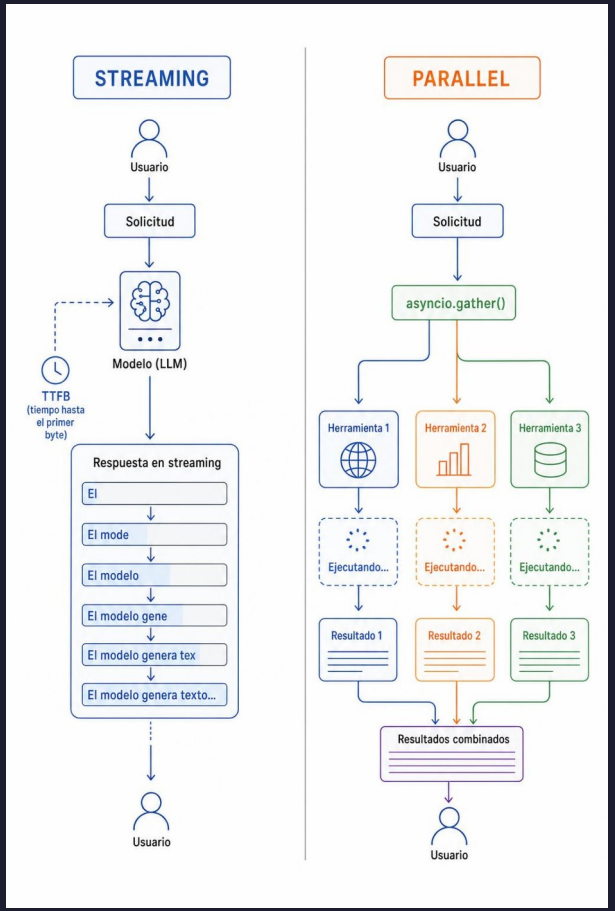
Model routing

- No uses siempre el modelo top
- Un clasificador rápido decide la complejidad
- Cascada: nano intenta, escala a mini y a frontier
- Frameworks: LiteLLM, RouteLLM, Martian
- Ahorro típico del 40-70 %



Streaming

- TTFT frente a tiempo total: el usuario ve la respuesta ya
- Mejora la latencia percibida, no la real
- stream=True en el SDK
- Compatible con casi cualquier arquitectura
- Mejora de UX inmediata y sin coste



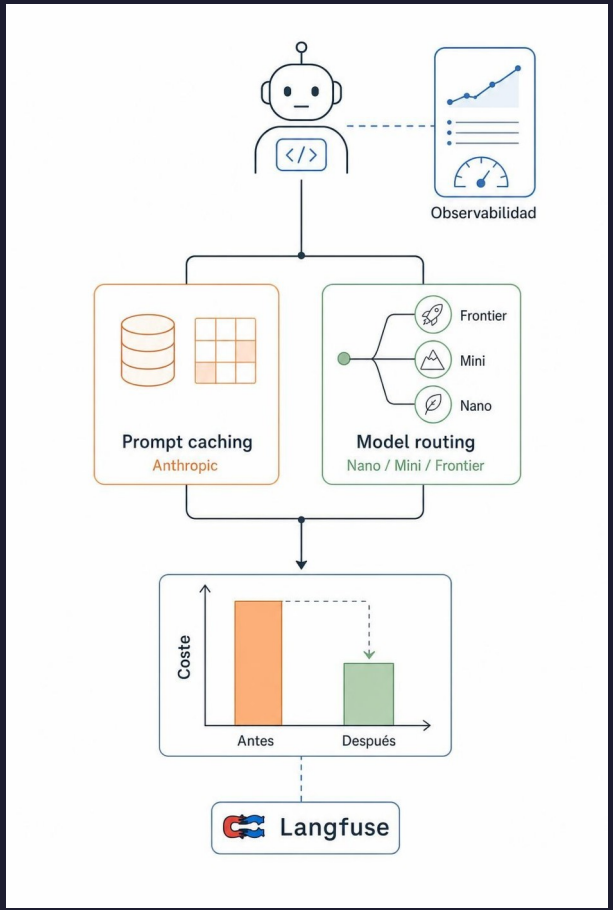
Llamadas en paralelo

- Llamadas independientes: paralelízalas
- asyncio.gather o ThreadPoolExecutor
- Caso: 10 tools que el agente llama a la vez
- Reduce la latencia total real
- Cuidado con los rate limits



Lab: caching + routing

- Baseline: todo a gpt-5-mini
- Prompt caching de OpenAI (y Anthropic opcional)
- Model routing nano / mini / frontier
- Medimos coste y latencia antes y después
- Lab: 01-prompt-caching-model-routing.ipynb




keep coding